

Informe de resultados — Series de tiempo de viajeros internacionales a Guatemala

Universidad del Valle de Guatemala Facultad de Ingeniería Departamento de Ciencias de la Computación CC3084 – Data Science Semestre II – 2026 Ricardo Godínez -23247 Vianka Castro -23201 Sebastian Bustamante -22291

Este informe reúne el análisis de las **siete series mensuales** construidas para el laboratorio: la serie **total** de viajeros internacionales ([notebooks/analisis_serie_total_internacional.ipynb](#)), las tres series por **vía de ingreso** — Aérea, Terrestre y Marítima ([notebooks/vias_de_ingreso.ipynb](#)) — y las tres series por **región geográfica** de origen — América del Centro, América del Norte y Europa ([notebooks/Analisis_zonas_geograficas.ipynb](#)). Se organiza siguiendo los cuatro bloques de la rúbrica del laboratorio (análisis de la serie, estacionariedad, generación de modelos y predicción), aplicados a cada una de las series. Antes de entrar a las series, la sección 0 resume el diagnóstico exploratorio ([notebooks/analisis_exploratorio.ipynb](#)) que justifica las decisiones de comparabilidad, calidad de datos y construcción que se usan en el resto del documento.

0. Análisis exploratorio de los datos

0.1 Fuente, comparabilidad y calidad de los datos

La base original está en formato largo: cada fila combina año, mes, vía, frontera, país, región y tipo de viajero, con el conteo correspondiente en **Viajero**. Cubre enero de 2009 a junio de 2026.

De las cuatro categorías de **Tipo de Viajero**, **Turista** (71.99% del acumulado) y **Excursionista** (17.34%) se mantienen consistentes en toda la serie; **Cruceristas** (2.11%) deja de reportarse desde 2023 y **Viajero** (8.55%) se reclasifica ese mismo año por un cambio metodológico. Por eso las series de este laboratorio usan únicamente Turista y Excursionista, lo que deja 137,642 registros y 46,711,913 visitantes acumulados. *Esta cifra todavía incluye la etiqueta de país "Guatemala"; su exclusión adicional se decide y se justifica en la sección 1.1, al construir la serie total internacional definitiva.*


La calidad de los datos es alta: no hay valores faltantes, duplicados exactos, fechas inválidas ni cantidades negativas, y la cobertura mensual es completa (210 de 210 meses esperados, 0 ausentes). Existen 54 combinaciones en cero, que se conservan porque representan combinaciones válidas sin flujo observado y no errores de captura.

0.2 Estadísticas descriptivas: nivel fila vs. nivel mensual

A nivel de registro individual la distribución es muy asimétrica (media de 339 visitantes, mediana de 7, máximo de 83,511): hay muchas combinaciones pequeñas y pocas de gran volumen. La escala relevante para modelar es la agregación mensual: media de 222,438 visitantes, desviación estándar de 84,725, mínimo de 9,779, máximo de 449,114 y un coeficiente de variación de 38.09%. Esta dispersión no debe interpretarse como ruido aleatorio: refleja crecimiento, estacionalidad, el choque de 2020 y la recuperación posterior.

0.3 Comportamiento temporal agregado


La media móvil de 12 meses muestra una trayectoria creciente con oscilaciones anuales antes de 2020, una caída abrupta desde marzo de ese año y una recuperación posterior clara.



La comparación anual indexada a 2019 = 100 cuantifica el choque y la recuperación: 2020 cae a 25.65 (–74.35% frente a 2019) y 2021 apenas sube a 26.59. El +193.85% de 2022 es engañoso si se lee de forma aislada, porque parte de una base extremadamente baja — en el índice equivale apenas a 78.15, todavía por debajo de 2019. Para 2024 y 2025 el índice se estabiliza en 79–81, sin llegar a 100 en esta versión preliminar de la serie (2026 solo cubre seis meses y no es comparable con años completos). *Este resultado corresponde a la base "con Guatemala"; al excluir esa etiqueta más adelante, la recuperación resulta más completa (sección 1.1).*


0.4 Concentración geográfica: países y regiones

El flujo está fuertemente concentrado: El Salvador (30.14%) y Guatemala (29.69%, residentes que reingresan al país) encabezan el acumulado por país, seguidos de Estados Unidos (14.91%) y Honduras (5.40%). Por región, **América del Centro** domina con 71.25% del acumulado, seguida de **América del Norte** (19.61%) y **Europa** (4.60%); el resto de regiones no supera el 3.1% cada una.




0.5 Vías y fronteras de ingreso

La vía **Terrestre** concentra 59.07% del acumulado (27.6 millones) y la **Aérea** 40.72% (19.0 millones); la **Marítima** apenas 0.21% (100 mil) — lo que anticipa por qué esa vía requirió un tratamiento de datos distinto en el resto del laboratorio. Por frontera, La Aurora (el aeropuerto) concentra 40.65% del acumulado y Valle Nuevo (frontera con El Salvador) 21.71%, seguidas de San Cristóbal, Pedro de Alvarado y La Ermita.



0.6 Cruce entre región y vía de ingreso


El cruce entre región y vía revela dos patrones de acceso claramente distintos: América del Centro ingresa mayoritariamente por **tierra** (73.8%, frente a 26.0% aérea), mientras que América del Norte (80.0% aérea), América del Sur y el Caribe (83.2% aérea) y Europa (64.2% aérea) dependen sobre todo de la **conectividad aérea**.



Esta composición explica por qué, más adelante, los hallazgos de la vía Terrestre y de la región América del Centro tienden a coincidir (comparten el mismo canal dominante), y por qué la vía Aérea se parece más al comportamiento de América del Norte y Europa.

0.7 Valores atípicos

A nivel de registro individual, 16.63% de los 137,642 registros supera el límite superior del criterio IQR — esperable dada la fuerte asimetría de una base tan granular, y no se eliminan porque corresponden a combinaciones legítimas de alto volumen. A nivel mensual, en cambio, solo **un mes** queda marcado como atípico: diciembre de 2019, con 449,114 visitantes, el pico histórico justo antes de la pandemia. Se conserva porque corresponde a un mes real y estacionalmente fuerte, no a un error de datos.



0.8 De la exploración a las series de tiempo

A partir de este diagnóstico se construyeron las **siete series mensuales** analizadas en el resto del informe: la serie total, las tres vías de ingreso y las tres regiones con mayor acumulado (América del Centro, América del Norte y Europa, determinadas con el período completo para que el ranking no dependa de un año en particular). Todas comparten el mismo inicio, fin y frecuencia mensual, y la misma partición cronológica 70/30 (147 meses de entrenamiento, 63 de prueba) detallada en la sección 2.

1. Series analizadas

1.1 Serie total internacional

Se construyó a partir de los registros clasificados como **Turista** o **Excursionista**, excluyendo la etiqueta de país **Guatemala** (residentes que reingresan al país). Ambos filtros responden a un problema de comparabilidad temporal: la fuente cambia de metodología en 2023 y, sin filtrarlos, la serie mezclaría universos distintos (**Cruceristas** deja de reportarse desde 2023, **Viajero** se reclasifica y pierde ~70% de nivel, y la etiqueta **Guatemala** desaparece por completo desde enero de 2023). El resultado es una serie mensual de 210 observaciones, de enero de 2009 a junio de 2026.

Al excluir la etiqueta **Guatemala**, la caída y la recuperación quedan más claras que en la vista preliminar de la sección 0.3: con índice 2019 = 100, 2020 baja a **22.73** (–77.3%), pero para 2024 el índice ya alcanza **134.82** (+34.8% sobre 2019) y en 2025 sube a 138.02 — es decir, esta versión de la serie no solo se recuperó, sino que superó ampliamente su nivel prepandemia.

1.2 Series por vía de ingreso

Se analizaron tres series mensuales de ingreso de viajeros a Guatemala según la vía utilizada: **Aérea**, **Terrestre** y **Marítima**, cada una con las mismas 210 observaciones mensuales. Para Aérea y Terrestre se usó el mismo criterio de comparabilidad (Turista y Excursionista). En la vía Marítima se encontró una limitación metodológica: desde 2017 existen registros marítimos, pero dejaron de aparecer bajo las categorías Turista y Excursionista. Por ello, la serie Marítima se construyó con todos los tipos de viajero, para no sustituir datos existentes por ceros artificiales; esto permite analizar su comportamiento durante todo el período, pero implica que sus

volúmenes no son completamente comparables con los de Aérea y Terrestre, ni con la serie total (que sí aplica el filtro Turista/Excursionista de forma estricta).

1.3 Series por región geográfica

Se analizaron también tres series mensuales según la región geográfica de origen de los visitantes, seleccionadas por ser las de mayor volumen acumulado en todo el período: **América del Centro, América del Norte y Europa**. Al igual que en las vías, se usó el criterio Turista/Excursionista para mantener comparabilidad temporal. Las tres regiones cubren exactamente el mismo período (enero 2009 – junio 2026, 210 meses), con la misma partición 70/30 (147 meses de entrenamiento, 63 de prueba) y sin meses faltantes.

Región	Inicio entrenamiento	Fin entrenamiento	Inicio prueba	Fin prueba	Meses entrenamiento	Meses prueba	Meses faltantes
América del Centro	2009-01	2021-03	2021-04	2026-06	147	63	0
América del Norte	2009-01	2021-03	2021-04	2026-06	147	63	0
Europa	2009-01	2021-03	2021-04	2026-06	147	63	0

América del Centro concentra el mayor volumen y una fuerte relación con el ingreso terrestre; América del Norte y Europa presentan niveles menores pero mayor dependencia de la conectividad aérea. En las tres regiones la caída de 2020 constituye una ruptura estructural y no una fluctuación estacional normal.


Series mensuales de las regiones principales



Resumen descriptivo (serie total y vías):

Serie	Media mensual	Desviación estándar	Mínimo	Máximo	Meses con cero
Total internacional	156,388.20	74,176.33	0.00	365,573.02	5
Aérea	90,568.66	27,855.30	489.00	158,463.00	0
Terrestre	131,391.68	60,815.99	5,240.00	291,272.07	0
Marítima	5,851.34	6,708.80	0.00	29,506.00	27

Las cuatro series comparten el mismo patrón general: crecimiento antes de 2020, una caída fuerte durante la pandemia y una recuperación posterior que, en todos los casos, retoma la trayectoria previa al choque. Diciembre fue el mes con mayor flujo promedio en las tres vías.




2. División en entrenamiento y prueba

La partición se hizo de forma **cronológica**, no aleatoria, para evitar fuga de información: el 70% inicial de los 210 meses para entrenamiento y el 30% final para prueba. El mismo punto de corte se aplicó a las **cuatro series**.

Conjunto	Período	Meses	Porcentaje
Entrenamiento	Enero 2009 – marzo 2021	147	70%
Prueba	Abril 2021 – junio 2026	63	30%

En el caso de Marítima, después de corregir su construcción, el conjunto de prueba contiene 52 meses con valores positivos y 11 meses en cero, por lo que ya no queda compuesto artificialmente solo por ceros. En la serie total, cinco meses del entrenamiento (abril-agosto de 2020) quedan en cero por el cierre de fronteras. La misma partición se aplicó a las tres series regionales, que también cubren exactamente 147 meses de entrenamiento y 63 de prueba, sin meses faltantes (ver Tabla en la sección 1.3).



3. Análisis de las series de tiempo


Para cada serie se revisa su gráfico y componentes, si presenta estacionalidad (y qué implica) y si presenta tendencia (y qué significa).

3.1 Serie total internacional

La serie muestra una tendencia de crecimiento sostenido, interrumpida por el colapso del turismo durante la emergencia sanitaria de 2020 (cinco meses en cero) y seguida de una recuperación que retoma la misma trayectoria previa. La descomposición aditiva (período 12) separa tendencia, estacionalidad y residuo; el residuo se mantiene estable durante casi todo el período y se dispara únicamente durante el choque, lo que confirma que se trata de un evento atípico y no de un cambio estructural del proceso generador.


- **Estacionalidad:** sí presenta. El rezago 12 es, de forma sistemática, el único rezago relevante tanto en la ACF como en la PACF de la serie transformada, con picos en marzo y diciembre y un valle en septiembre (amplitud estacional equivalente al 51% de la media de la serie). La fuerza de estacionalidad (Hyndman & Athanasopoulos) es de 0.46 sobre el entrenamiento completo y sube a 0.73 al excluir el choque de 2020, que distorsiona el patrón anual. Esto implica que el modelo debe incorporar un componente estacional explícito (una diferencia estacional $D = 1$ con período 12 y un término MA estacional $Q = 1$); ignorarlo dejaría sin explicar una parte recurrente y sustancial de la variación mes a mes.
- **Tendencia:** sí presenta. La fuerza de tendencia es de 0.80 sobre el entrenamiento completo y de 0.88 al excluir el choque, claramente dominante frente a la estacionalidad en ambos casos, y equivale a un crecimiento interanual aproximado del 7% sobre la ventana pre-choque. Esto significa que la serie no fluctúa alrededor de un nivel fijo, sino que crece de forma sostenida en el tiempo salvo por el quiebre puntual de 2020; por eso el modelo final incorpora un término constante que representa esa tasa de crecimiento.

Descomposición aditiva de la serie de entrenamiento (período = 12)




3.2 Serie Aérea

- **Estacionalidad:** presenta una estacionalidad **moderada**, con fuerza de 0.384. Es un componente presente pero no dominante: el flujo aéreo depende del mes del año, con diciembre como el mes de mayor volumen, pero en menor medida que las otras dos vías.
- **Tendencia:** presenta una tendencia **importante**, con fuerza de 0.613, y una pendiente mensual relativa de 0.43% antes de 2020. Significa que el turismo aéreo venía en expansión sostenida antes de la pandemia, aunque de forma más moderada que la vía terrestre.




3.3 Serie Terrestre

- **Estacionalidad:** presenta una estacionalidad **moderada**, con fuerza de 0.409, similar a la de Aérea.
- **Tendencia:** presenta la tendencia **más fuerte de las tres vías**, con un valor de 0.818 y la mayor pendiente mensual relativa antes de la pandemia (0.87%). Esto significa que el ingreso terrestre fue el canal con mayor crecimiento estructural en el largo plazo, previo al choque de 2020.



3.4 Serie Marítima


- **Estacionalidad:** presenta la **mayor fuerza estacional** de las cuatro series, con un valor de 0.641. Implica que el flujo marítimo depende en mayor medida del mes del año que el resto de vías, y que un modelo sin componente estacional explicaría mal su comportamiento.
- **Tendencia:** presenta una tendencia **moderada**, con fuerza de 0.576 y una pendiente mensual relativa de 0.44% antes de 2020, similar a la de Aérea. También es la serie con mayor variabilidad relativa (coeficiente de variación de 1.15) y con un comportamiento considerablemente más irregular, en parte por la limitación de datos descrita en la sección 1.2.



3.5 Región América del Centro

- **Estacionalidad:** fuerza de 0.36 dentro del entrenamiento completo (sube a 0.69 si se excluye la pandemia, ver sección 7.2), con diciembre como mes de mayor actividad y septiembre como el más bajo. El patrón aparece menos regular que en las otras regiones porque la magnitud del choque de 2020 se mezcla con el residuo.
- **Tendencia:** fuerza de 0.77 dentro del entrenamiento completo, la segunda más alta de las tres regiones. Implica un crecimiento pronunciado antes de 2020, seguido de una caída que se refleja principalmente en la tendencia y en el residuo, por no ser un patrón que se repita cada año.


Descomposición aditiva — América Del Centro



3.6 Región América del Norte


- **Estacionalidad:** fuerza de 0.57 dentro del entrenamiento completo, con diciembre como mes de mayor actividad y septiembre como el más bajo — un ciclo anual más claro que el de América del Centro.
- **Tendencia:** fuerza de 0.64, la más moderada de las tres regiones. El residuo aumenta de forma considerable durante la ruptura de 2020, señal de que ese evento no queda explicado ni por la tendencia ni por la estacionalidad.

Descomposición aditiva — América Del Norte



3.7 Región Europa

- **Estacionalidad:** presenta la mayor fuerza estacional de las tres regiones dentro del entrenamiento, con 0.76, y el patrón más regular. A diferencia de las otras dos, su pico ocurre en febrero y su valle en junio.
- **Tendencia:** presenta la mayor fuerza de tendencia de las tres regiones, con 0.81. Igual que en el resto de series, la pandemia produce una desviación que la estacionalidad normal no puede explicar.





4. Determinación de estacionariedad

Para cada serie se evalúa si es estacionaria en varianza (aplicando una transformación si no lo es) y si es estacionaria en media (con ACF y la prueba ADF), determinando cuántas diferenciaciones se necesitan.


4.1 Serie total internacional

Varianza. No es estacionaria en varianza: al dividir el entrenamiento en tercios, la desviación estándar crece de forma aproximadamente proporcional al nivel de la serie (correlación media-desviación de 0.887), característica propia de un proceso multiplicativo. Se aplicó una **transformación logarítmica $\log_{1p}$** (y no $\log$ simple, porque hay meses con valor cero); tras la transformación la desviación por tercios queda prácticamente constante.

Media. Tampoco es estacionaria en media: la media móvil de 12 meses varía entre 14,908 y 205,144 visitantes, la ACF en nivel decae de forma lenta (9 de 36 rezagos significativos, con $ACF(1) = 0.80$ y el primer rezago no significativo hasta el 10) y la prueba ADF no rechaza la raíz unitaria salvo en una especificación puntual, mientras KPSS tampoco confirma estacionariedad. Se determinó que se necesita **una diferenciación estacional ($D = 1, s = 12$)**; se comprobó explícitamente, mediante una escalera de diferenciación evaluada con ADF/KPSS, que añadir además una diferencia regular ($d = 1$) sobre-diferencia la serie (la desviación aumenta en vez de bajar), por lo que se descartó y se mantuvo **$d = 0$** con término constante.




Escalera de diferenciación sobre log1p



4.2 Serie Aérea

Varianza. La transformación logarítmica no mejoró la estabilidad de la varianza, por lo que la serie se conservó en su escala original.


Media. La prueba ADF aplicada a la serie original produjo un valor p de 0.15, por lo que no se consideró estacionaria en media. Para alcanzar estacionariedad se aplicó **una diferencia regular ($d = 1$, $D = 0$)**; después de diferenciar, la prueba ADF produjo un valor p cercano a cero, confirmando la estacionariedad.



4.3 Serie Terrestre

Varianza. Al igual que en Aérea, la transformación logarítmica no produjo una mejora suficiente en la estabilidad de la varianza, por lo que se conservó la escala original.


Media. La prueba ADF sobre la serie original produjo un valor p de 0.24, indicando que no era estacionaria. Se aplicó **una diferencia regular ($d = 1$, $D = 0$)**; después de diferenciar, la prueba ADF produjo un valor p de 0.01, confirmando la estacionariedad en media.



4.4 Serie Marítima

Varianza. A diferencia de Aérea y Terrestre, la relación entre el nivel de la serie y su variabilidad fue alta, por lo que se aplicó la transformación **log1p**.

Media. La prueba ADF de la serie transformada produjo un valor p de 1.00, por lo que fue necesario aplicar **dos diferencias regulares**: los valores seleccionados fueron **d = 2, D = 0**. Después de diferenciar, el valor p de la prueba ADF fue cercano a cero. Es, de las cuatro series, la que requirió mayor grado de diferenciación.



4.5 Región América del Centro

Varianza. La relación entre la media y la desviación móvil es débil (correlación de 0.15) y el parámetro de Box-Cox (0.88) no se aproxima a cero, por lo que no hay evidencia fuerte de que la transformación logarítmica sea estrictamente necesaria. Aun así, el coeficiente de variación crece de 0.24 en la primera mitad del entrenamiento a 0.46 en la segunda, sobre todo por la ruptura de 2020. Se aplicó $\log(1+x)$ como decisión conservadora de modelado, no porque la varianza lo exigiera de forma estricta.

Media. La prueba ADF sobre el log-nivel produjo un valor p de 0.20, sin rechazar la raíz unitaria; la ACF confirma persistencia (0.88 en el rezago 1 y 0.35 en el rezago 6). Una diferencia regular basta para reducir el valor p a 0.04, y se añadió además una diferencia estacional para eliminar el patrón anual: $d = 1, D = 1$.

4.6 Región América del Norte

Varianza. La correlación entre media y desviación móvil es negativa (-0.34) y el Box-Cox (1.53) tampoco se acerca a cero; la evidencia de varianza no constante es débil. El coeficiente de variación también crece en la segunda mitad del entrenamiento ($0.22 \rightarrow 0.45$). Se aplicó la misma transformación conservadora, $\log(1+x)$.


Media. La prueba ADF en nivel rechaza la raíz unitaria ($p = 0.01$), pero deja de hacerlo tras aplicar el logaritmo ($p = 0.16$), por lo que la diferenciación se estudió sobre la escala transformada. La primera diferencia queda al límite de significancia ($p \approx 0.05$); combinada con una diferencia estacional, rechaza claramente la raíz unitaria: $d = 1, D = 1$.

4.7 Región Europa

Varianza. La correlación media-desviación es -0.23 y el Box-Cox (1.68) tampoco se aproxima a cero. El coeficiente de variación crece de 0.23 a 0.49 entre ambas mitades del entrenamiento. Se aplicó igualmente $\log(1+x)$ como decisión conservadora.

Media. El valor p de ADF en log-nivel es 0.28 ; una primera diferencia regular todavía deja un valor p de 0.11 , insuficiente. La diferencia estacional de doce meses sí produce un valor p menor a 0.001 , por lo que Europa necesita $D = 1$ pero no una diferencia regular adicional ($d = 0$) — la única de las siete series que no requiere diferenciación regular.









Nota metodológica: a diferencia de las vías, en las regiones la evidencia de no-estacionariedad en varianza (correlación media-desviación, Box-Cox) resultó débil en las tres; el uso de $\log(1+x)$ se mantuvo como decisión conservadora de modelado y no como una transformación estrictamente exigida por los datos.

5. Generación de modelos

Para cada serie se identifican p , d , q a partir de la ACF y la PACF, se explican los modelos elegidos (incluidos los propuestos automáticamente), se generan los cuatro algoritmos solicitados y se comparan por residuos, métricas de error, AIC y BIC.

5.1 Serie total internacional


Identificación de p , d , q vía ACF y PACF. Sobre la serie ya transformada ($\log 1p$ + diferencia estacional), ni la ACF ni la PACF muestran rezagos significativos en el corto plazo (1 a 6), por lo que la parte no estacional queda vacía: $p = 0$, $q = 0$. El único rezago relevante es el 12, presente en ambas funciones; como la ACF corta en seco en el rezago 24 mientras la PACF decae de forma gradual, la regla de Box-Jenkins identifica un componente de medias móviles estacional: $P = 0$, $Q = 1$. Con $D = 1$ y $d = 0$, el modelo resultante es un **SARIMA(0,0,0)(0,1,1)₁₂ con constante**, llamado M1 en el notebook.



Explicación de la elección de parámetros, incluidos los automáticos. Además de M1, se ajustó una malla automática de 36 combinaciones de órdenes alrededor de esa propuesta y un modelo "airline" $(0,1,1)(0,1,1)_{12}$


clásico (M3), para contrastar la lectura manual contra una búsqueda exhaustiva. La malla confirma de forma independiente la parte estacional $(0,1,1)_{12}$ en los cinco mejores órdenes; el mejor por AIC agrega dos términos autorregresivos (M2, orden $(2,0,0)(0,1,1)_{12}$), con una mejora de apenas 4.9 puntos de AIC sobre M1 — evidencia débil frente al costo de dos parámetros adicionales —, por lo que por parsimonia se prefiere M1. También se comprobó que el ajuste depende críticamente de la ventana de entrenamiento: sobre el entrenamiento completo (que incluye el choque) ningún coeficiente estacional resulta significativo, mientras que sobre la ventana pre-choque (2009-01 a 2020-02) los tres coeficientes de M1 son significativos ($p < 0.001$).

Modelos generados con los distintos algoritmos. Se generaron seasonal naive (línea base), suavizamiento exponencial simple y Holt-Winters (aditivo y amortiguado), cada uno sobre la ventana de entrenamiento completa y sobre la ventana pre-choque. *Nota:* Prophet no estaba disponible en el entorno de ejecución; como el enunciado admite cualquiera de las alternativas, se implementaron en su lugar las tres restantes.




Comparación por residuos, métricas de error, AIC y BIC. Los residuos de los tres SARIMA sobre la ventana completa fallan la prueba de heterocedasticidad y muestran curtosis muy por encima de lo esperado en una distribución normal; sobre la ventana pre-choque los tres pasan Ljung-Box, la heterocedasticidad ya no se rechaza y la curtosis baja a un rango razonable. El AIC y el BIC solo se compararon dentro de la familia SARIMA: AIC prefiere a M2 y BIC a M3, con M1 muy cerca de ambos; las diferencias son pequeñas y no discriminan de forma concluyente dentro de la muestra. Frente a Holt-Winters y seasonal naive, la comparación se hizo exclusivamente con métricas de error sobre el conjunto de prueba, no con AIC/BIC.

Diagnóstico de residuos — ventana B — completa (2009-01→2021-03)



Diagnóstico de residuos — ventana C — pre-choque (2009-01→2020-02)



5.2 Serie Aérea

La función de autocorrelación parcial sugirió $p = 2$, mientras que la función de autocorrelación sugirió $q = 2$, sobre la serie diferenciada ($d = 1$). A partir de estos resultados se compararon diferentes modelos ARIMA y SARIMA cercanos. El mejor candidato de esta familia fue:


SARIMA (0,1,2)(1,0,1,12)


Este modelo obtuvo un AIC de 2,869.86, un BIC de 2,884.24 y un valor p de Ljung-Box de 0.65 en entrenamiento, lo que indica que sus residuos no conservaron autocorrelación significativa dentro del conjunto usado para ajustarlo.

También se generaron los modelos Prophet, Holt-Winters, suavizamiento exponencial y Seasonal Naive. Los resultados sobre el conjunto de prueba fueron:

Modelo	MAE	RMSE
Suavizamiento exponencial	36,970.60	42,141.22
Prophet	41,271.36	45,655.27
Holt-Winters	43,072.93	47,051.02
Seasonal Naive	75,512.73	79,339.80
ARIMA/SARIMA	74,524.43	79,593.05

El mejor resultado fue obtenido por **suavizamiento exponencial**, con los menores valores de MAE y RMSE. Sin embargo, sus residuos de prueba conservaron autocorrelación significativa, por lo que el modelo todavía dejó patrones temporales sin explicar completamente.





5.3 Serie Terrestre

La PACF sugirió $p = 3$, mientras que la ACF sugirió $q = 2$. Después de comparar diferentes combinaciones, el mejor modelo de la familia ARIMA/SARIMA fue:


SARIMA (0,1,2)(1,0,1,12)


Este modelo obtuvo un AIC de 3,091.31, un BIC de 3,105.69 y un valor p de Ljung-Box de 0.55 en entrenamiento, por lo que sus residuos de entrenamiento no mostraron autocorrelación significativa.

Los modelos comparados en prueba presentaron los siguientes resultados:

Modelo	MAE	RMSE
Prophet	47,713.21	57,657.61
Suavizamiento exponencial	121,715.64	134,136.23
Holt-Winters	128,421.20	139,161.45
Seasonal Naive	132,209.04	144,274.98
ARIMA/SARIMA	147,398.53	158,502.92

El mejor modelo fue **Prophet**, con una diferencia amplia respecto de los demás algoritmos. Este resultado sugiere que su capacidad para representar cambios de tendencia fue más adecuada para una serie afectada por el choque de 2020 y la recuperación posterior. A pesar de obtener los menores errores, sus residuos de prueba conservaron autocorrelación significativa.





5.4 Serie Marítima

La PACF sugirió $p = 3$ y la ACF sugirió $q = 2$. El mejor candidato ARIMA/SARIMA fue:


SARIMA (0,2,2)(1,0,1,12)


Este modelo obtuvo un AIC de 551.92, un BIC de 566.26 y un valor p de Ljung-Box de 0.07 en entrenamiento. Entre los candidatos evaluados, fue uno de los que combinó valores bajos de AIC y BIC con residuos sin autocorrelación significativa al nivel de 5%.

Los resultados de prueba fueron:

Modelo	MAE	RMSE
Holt-Winters	902.62	1,685.06
Suavizamiento exponencial	858.37	1,731.93
Seasonal Naive	858.37	1,731.93
ARIMA/SARIMA	858.37	1,731.93
Prophet	7,272.58	8,587.77

Aunque varios modelos obtuvieron un MAE ligeramente menor, **Holt-Winters** presentó el menor RMSE, un sesgo relativamente bajo y residuos de prueba sin autocorrelación significativa (Ljung-Box $p = 0.19$), por lo que fue seleccionado como el modelo más adecuado para esta serie. Sus errores no deben compararse directamente con los de Aérea y Terrestre, debido a la diferencia de escala y a la limitación metodológica de su construcción.





5.5 Región América del Centro

Se exploraron valores de p y q entre 0 y 2 sobre la serie diferenciada (d = 1, D = 1). El modelo seleccionado fue:

SARIMA(1,1,1)(1,1,0)[12]

Obtuvo un AIC de 50.59, un BIC de 61.78 y un valor p de Ljung-Box de 0.84 en el rezago 12, por lo que sus residuos no mostraron dependencia serial significativa dentro del entrenamiento.

Se compararon cinco enfoques sobre el conjunto de prueba (ARIMA/SARIMA, Prophet, Holt-Winters amortiguado, suavizamiento exponencial simple y seasonal naive):

Modelo	MAE	RMSE
Suavizamiento exponencial	108,285	120,341
Holt-Winters	113,415	124,214
Seasonal naïve	134,400	144,899
ARIMA/SARIMA	150,584	163,920
Prophet	156,597	166,857

El mejor resultado en prueba fue el **suavizamiento exponencial simple**. El entrenamiento termina cerca del punto más bajo de actividad, y los modelos con tendencia y componentes más complejos —incluido el SARIMA seleccionado por AIC/BIC— extrapolaron patrones que no representaron bien la reapertura posterior.

5.6 Región América del Norte

Con la misma exploración de p y q entre 0 y 2, el modelo seleccionado fue:

SARIMA(1,1,1)(1,1,0)[12]

Obtuvo un AIC de 382.00, un BIC de 393.18 y un valor p de Ljung-Box de 0.75. Sus diagnósticos dentro del entrenamiento fueron adecuados, pero al proyectarlo sobre el conjunto de prueba produjo una **trayectoria**

explosiva — evidencia de que buenos diagnósticos dentro de la muestra no garantizan estabilidad en un horizonte largo que atraviesa un cambio estructural como la pandemia.

Modelo	MAE	RMSE
Suavizamiento exponencial	32,194	36,725
Holt-Winters	40,797	44,976
Seasonal naïve	49,974	53,533
Prophet	55,626	59,244
ARIMA/SARIMA	5.69×10^{22}	2.63×10^{23}

El **suavizamiento exponencial simple** fue nuevamente el mejor modelo en prueba, por la misma razón que en América del Centro: el corte de entrenamiento coincide con el nivel más bajo de actividad.

5.7 Región Europa


Para Europa ($d = 0$, $D = 1$) se seleccionó:

ARIMA(1,0,1)


Obtuvo un AIC de 360.86, un BIC de 372.76 y un valor p de Ljung-Box de 0.87. Algunos candidatos estacionales lograron un BIC menor, pero conservaron autocorrelación residual significativa y fueron descartados por ese criterio.

Modelo	MAE	RMSE
ARIMA/SARIMA	6,420	7,824
Suavizamiento exponencial	9,292	10,695
Holt-Winters	10,378	11,563
Seasonal naïve	11,076	12,135
Prophet	11,676	12,887

A diferencia de las otras dos regiones, aquí **ARIMA(1,0,1)** fue el mejor modelo en prueba: capturó la dependencia de corto plazo sin producir la inestabilidad observada en el SARIMA de América del Norte.



Pronósticos regionales sobre el conjunto de prueba



Nota: en América del Norte la proyección SARIMA excede ampliamente la escala de los datos; la figura anterior la recorta únicamente para conservar la legibilidad, pero las métricas de la tabla se calcularon con los valores completos, sin recortar.

5.8 Comparación de los modelos seleccionados

Serie	Mejor modelo	MAE	RMSE	Autocorrelación en residuos de prueba
Total internacional	Holt-Winters amortiguado (ventana pre-choque)	53,568.42	75,695.20	No significativa
Aérea	Suavizamiento exponencial	36,970.60	42,141.22	Sí
Terrestre	Prophet	47,713.21	57,657.61	Sí
Marítima	Holt-Winters	902.62	1,685.06	No significativa

Serie	Mejor modelo	MAE	RMSE	Autocorrelación en residuos de prueba
América del Centro	Suavizamiento exponencial	108,285.00	120,341.00	No reportada
América del Norte	Suavizamiento exponencial	32,194.00	36,725.00	No reportada
Europa	ARIMA(1,0,1)	6,420.00	7,824.00	No significativa (Ljung-Box p = 0.87 en entrenamiento)

Nota de comparabilidad: ninguna de las tres familias de series (total, vías, regiones) se evaluó con exactamente el mismo procedimiento. La serie total descarta explícitamente todo modelo peor que su seasonal naive y contrasta dos ventanas de entrenamiento; vías y regiones se ajustaron sobre una única ventana de 147 meses, pero regiones no reporta la autocorrelación de los residuos de prueba para los modelos de suavizamiento, solo el Ljung-Box de entrenamiento de los candidatos ARIMA/SARIMA. Los RMSE de la tabla no deben leerse como una carrera directa entre las siete series, sino como el resumen de cuál algoritmo ganó en cada una.

El análisis demuestra que **no existe un único algoritmo que funcione mejor para todas las series**: cada una necesitó un modelo diferente de acuerdo con su tendencia, estacionalidad, variabilidad y presencia de cambios estructurales. AIC y BIC se usaron principalmente para comparar candidatos ARIMA/SARIMA y modelos de suavizamiento cuando estaban disponibles; Prophet y Seasonal Naive se compararon sobre todo mediante los errores en el conjunto de prueba y el comportamiento de los residuos. El caso de América del Norte añade una advertencia adicional: ni el AIC ni el BIC ni el Ljung-Box de entrenamiento anticiparon la inestabilidad de su SARIMA fuera de muestra.




6. Predicción con los modelos generados


Los conjuntos de entrenamiento y prueba ya se describieron en la sección 2 y son los mismos para las siete series. Aquí se resume qué tan bien predice cada modelo seleccionado y cómo se comparan entre sí.

6.1 Serie total internacional

El desempeño depende casi por completo de la ventana de entrenamiento, más que del algoritmo elegido: los modelos entrenados con toda la serie (incluyendo el choque) quedan anclados en el piso pandémico y nunca alcanzan el nivel real del conjunto de prueba; su mejor RMSE es 174,266. Los modelos entrenados sobre la ventana pre-choque, en cambio, sí capturan el nivel y la trayectoria correctos, con RMSE entre 75,695 y 81,574 entre los que superan al seasonal naive. Vistos por sub-período, en 2021 (piso pandémico) los modelos pre-choque fallan (MAPE superior al 290%), pero a partir de 2023 la serie observada entra en la banda de confianza del 95% de estos modelos y no vuelve a salir; para 2024-2026, ya con la serie normalizada, el mejor modelo alcanza un MAPE de apenas 8.7%.

Sobre el conjunto de prueba, cualquier modelo entrenado en la ventana completa resulta peor que el seasonal naive de esa misma ventana y se descarta. El mejor resultado global es **Holt-Winters amortiguado sobre la ventana pre-choque**, seguido muy de cerca por el SARIMA **M1 (0,0,0)(0,1,1)₁₂ con constante**, también sobre la ventana pre-choque, la misma especificación identificada manualmente. Ambos reproducen con precisión la forma del ciclo anual desde 2023 en adelante.





6.2 Series por vía de ingreso

Los modelos se ajustaron con las 147 observaciones de entrenamiento y se evaluaron sobre 63 meses que no participaron en su estimación. La comparación se realizó mediante MAE, RMSE, sesgo promedio y la prueba de Ljung-Box aplicada a los residuos.

Para **Aérea**, el suavizamiento exponencial presentó el mejor desempeño de prueba. Sin embargo, el RMSE de 42,141.22 representa un error relevante frente a una media mensual de 90,568.66. Además, los residuos conservaron autocorrelación, por lo que el modelo no capturó completamente la recuperación posterior a la pandemia.

Para **Terrestre**, Prophet obtuvo el menor error, con un RMSE de 57,657.61. Frente a una media mensual de 131,391.68, el error sigue siendo considerable, pero fue claramente inferior al de los demás algoritmos. La autocorrelación restante en los residuos indica que todavía quedaron patrones por explicar.

Para **Marítima**, Holt-Winters obtuvo un RMSE de 1,685.06 frente a una media mensual de 5,851.34. Sus residuos no conservaron autocorrelación significativa, lo que indica que capturó de mejor forma la estructura temporal disponible en el conjunto de prueba. Aun así, la predicción marítima debe considerarse exploratoria debido a los cambios metodológicos de la serie.

En general, los modelos permiten aproximar el comportamiento de los ingresos migratorios, pero no deben utilizarse como predicciones exactas: la pandemia produjo un quiebre estructural importante y el período de prueba incluye una recuperación distinta del comportamiento observado en buena parte del entrenamiento. Por ello, los pronósticos deben actualizarse periódicamente con nueva información.

6.3 Series por región geográfica

Para **América del Centro y América del Norte**, el suavizamiento exponencial simple fue el modelo con menor error en prueba. En ambos casos el entrenamiento termina cerca del punto más bajo de actividad turística, y los modelos con componentes de tendencia y estacionalidad más complejos —incluidos los SARIMA seleccionados por AIC/BIC— extrapolaron patrones que no representaron bien la reapertura posterior; en América del Norte esto fue especialmente grave, con el SARIMA produciendo una proyección explosiva y errores fuera de cualquier escala razonable.

Para **Europa**, en cambio, el mejor modelo fue el propio **ARIMA(1,0,1)**, con un RMSE de 7,824 frente a los 10,695–12,887 de las alternativas. Capturó la dependencia de corto plazo sin la inestabilidad del caso norteamericano.

No existe un modelo universalmente superior para las tres regiones: el mejor método depende de la escala, del comportamiento histórico y de la forma en que cada región respondió a la ruptura de 2020. El caso de América del Norte, en particular, demuestra que los diagnósticos de residuos dentro del entrenamiento no bastan por sí solos: es indispensable evaluar también el comportamiento del modelo fuera de muestra.

7. Análisis comparativo de las series

7.1 Vías de ingreso

Serie	Fuerza estacional	Fuerza de tendencia	Coefficiente de variación	Pendiente mensual relativa antes de 2020	Cambio 2020 frente a 2019
Aérea	0.384	0.613	0.31	0.43%	-72.80%
Terrestre	0.409	0.818	0.46	0.87%	-75.23%
Marítima	0.641	0.576	1.15	0.44%	-67.89%

La serie total no se incluye en esta tabla porque su fuerza de tendencia y estacionalidad se calcularon con una metodología distinta (por ventana, antes y después de excluir el choque — ver sección 3.1); no son directamente comparables punto a punto con estos valores.

¿Cuál vía presenta mayor estacionalidad? La vía **Marítima** presentó la mayor fuerza estacional, con un valor de 0.641. Esto indica que su flujo depende en mayor medida del mes del año. Aérea y Terrestre también presentaron patrones estacionales, pero con menor intensidad.

¿Cuál vía presenta mayor tendencia de crecimiento? La vía **Terrestre** presentó la tendencia más fuerte, con un valor de 0.818, y la mayor pendiente mensual relativa antes de la pandemia ($\approx 0.87\%$). Aérea presentó una pendiente relativa de 0.43% y Marítima de 0.44%.

¿Cuál vía presenta mayor volatilidad? La vía **Marítima** presentó la mayor volatilidad relativa, con un coeficiente de variación de 1.15, considerablemente superior al de Terrestre (0.46) y Aérea (0.31). La elevada dispersión marítima puede estar relacionada tanto con la naturaleza de este flujo como con los cambios metodológicos documentados.

¿Cuál vía fue más afectada por la pandemia? La vía **Terrestre** presentó la mayor caída entre 2019 y 2020, con una reducción de 75.23%. La vía Aérea disminuyó 72.80% y Marítima 67.89%. Estos resultados muestran que las restricciones de movilidad afectaron especialmente los ingresos por fronteras terrestres.

Comparación general. Aérea fue la serie menos volátil y presentó un comportamiento relativamente más estable. Terrestre mostró el mayor crecimiento previo a la pandemia, pero también la caída porcentual más fuerte en 2020. Marítima presentó la mayor estacionalidad y volatilidad, además de cambios de clasificación que reducen su comparabilidad directa. La serie total, al ser una agregación de las vías bajo el criterio Turista/Excursionista (que excluye la reconstrucción especial de Marítima), refleja sobre todo la dinámica combinada de Aérea y Terrestre: por eso su fuerza de tendencia (0.80 sobre el entrenamiento completo) es casi tan alta como la de Terrestre (0.818), la más alta de las cuatro series.

7.2 Regiones geográficas

Para evitar que la pandemia distorsione las características estructurales, estas comparaciones se calcularon sobre el período enero 2009 – diciembre 2019 (excluyendo el choque), y el impacto y la recuperación se midieron comparando 2020 y 2024 contra 2019.

Región	Fuerza estacional pre-2020	Crecimiento anual compuesto 2009-2019	Volatilidad interanual pre-2020	Impacto 2020 vs. 2019	Recuperación 2024 vs. 2019
América del Centro	0.69	9.83%	14.49%	-74.43%	-34.87%
América del Norte	0.89	3.81%	11.98%	-74.14%	+33.56%
Europa	0.88	2.33%	12.74%	-71.83%	+17.98%

¿Cuál región presenta mayor estacionalidad? **América del Norte**, con 0.89, muy cerca de Europa (0.88). América del Centro queda más atrás, con 0.69. Estos valores difieren de los reportados en la sección 3 porque aquí se excluye la ruptura de 2020, que distorsiona el patrón estacional normal.

¿Cuál región presenta mayor tendencia de crecimiento? **América del Centro**, con un crecimiento anual compuesto de 9.83% entre 2009 y 2019, muy por encima de América del Norte (3.81%) y Europa (2.33%).

¿Cuál región presenta mayor volatilidad? **América del Centro** también, con una volatilidad interanual de 14.49% frente a 12.74% en Europa y 11.98% en América del Norte: el crecimiento más acelerado vino acompañado de variaciones relativas más amplias.

¿Cuál región fue más afectada por la pandemia? Las tres cayeron de forma similar en 2020 (entre -71.83% y -74.43%), lo que confirma que el choque fue generalizado y no específico de una región. La diferencia aparece en la recuperación: para 2024, América del Norte y Europa ya superaban su nivel de 2019 (+33.56% y +17.98%), mientras que América del Centro seguía 34.87% por debajo — la única de las tres regiones que no había recuperado su nivel prepandemia.

Comparación general. América del Centro combina el mayor crecimiento histórico con la mayor volatilidad y la recuperación más débil frente a 2019; América del Norte y Europa crecieron con más moderación pero se recuperaron con más solidez. Esto contrasta con el patrón de las vías: allí Terrestre —el canal dominante de América del Centro— fue también el más golpeado por la pandemia (sección 7.1), reforzando la misma lectura desde dos ángulos distintos de la serie.

8. Descubrimientos útiles para INGUAT

- 1. Diciembre concentra el mayor flujo promedio en las tres vías de ingreso.** Este patrón puede utilizarse para anticipar una mayor demanda de personal, información turística, transporte y atención en los puntos de ingreso durante ese mes.
- 2. La vía Terrestre concentra el 59.07% del volumen acumulado (27.6 millones de visitantes) y tuvo el mayor crecimiento estructural antes de la pandemia,** con la pendiente mensual relativa más alta de las tres vías (0.87%). Es el canal prioritario para inversión en infraestructura fronteriza — La Aurora, Valle Nuevo, San Cristóbal, Pedro de Alvarado y La Ermita concentran juntas más del 80% del acumulado por frontera — y para acciones dirigidas a visitantes regionales.

3. **Terrestre fue también la vía más golpeada por la pandemia** (–75.23% en 2020), y América del Centro —que ingresa 73.8% de sus visitantes por tierra— es, de las tres regiones, la única que en 2024 seguía 34.87% por debajo de su nivel de 2019. La recuperación del mercado centroamericano por la vía terrestre debería ser una prioridad de promoción y facilitación fronteriza.
4. **Aérea presenta la menor volatilidad relativa** (coeficiente de variación de 0.31). Su comportamiento más estable permite planificar capacidad aeroportuaria y coordinar con aerolíneas con mayor certeza que en Terrestre o Marítima.
5. **Marítima requiere una revisión de calidad y consistencia de datos.** Los cambios en la clasificación de viajeros desde 2017 dificultan la comparación histórica. Mantener definiciones homogéneas y documentar claramente cualquier cambio en las categorías mejoraría la confiabilidad de futuras decisiones basadas en esta vía.
6. **La conectividad debe planificarse por región de origen.** América del Centro depende principalmente de accesos terrestres, mientras que América del Norte (80.0% aérea) y Europa (64.2% aérea) dependen sobre todo de la conectividad aérea; la inversión en infraestructura fronteriza y las alianzas con aerolíneas deben diferenciarse según el mercado de origen.
7. **La recuperación debe compararse contra el nivel de 2019, no solo contra el fondo de la pandemia.** Con ese criterio, América del Norte (+33.56%) y Europa (+17.98%) ya habían superado su nivel prepandemia en 2024, mientras que América del Centro (–34.87%) no — un argumento para concentrar esfuerzos de recuperación y promoción en el mercado centroamericano.
8. **América del Centro combina el mayor crecimiento histórico con la mayor volatilidad de las tres regiones** (9.83% de crecimiento anual compuesto entre 2009 y 2019, frente a una volatilidad interanual de 14.49%). Es el mercado de mayor potencial, pero también el que más exige monitoreo cercano y estrategias de contingencia ante variaciones bruscas.
9. **Estados Unidos (14.91% del acumulado) y Honduras (5.40%) son, después de El Salvador y de los residentes guatemaltecos, los orígenes de mayor volumen.** Junto con la fuerte dependencia aérea de América del Norte, esto refuerza a Estados Unidos como mercado prioritario para mantener y ampliar rutas y frecuencias aéreas.
10. **Las proyecciones deben tratarse como rangos de planificación, no como cifras exactas, y actualizarse con cada nuevo mes de datos disponible.** La pandemia produjo un quiebre estructural cuya recuperación todavía está en curso y difiere en ritmo por vía y por región, por lo que cualquier pronóstico usado para planificar debe revisarse conforme se incorpore información reciente.

9. Conclusiones generales

Las siete series analizadas comparten un mismo patrón de fondo —crecimiento antes de 2020, colapso durante la pandemia y recuperación posterior— pero difieren en la intensidad de su estacionalidad, su tendencia, su volatilidad y en qué tan completa fue esa recuperación, y requirieron tratamientos estadísticos específicos. Aérea mostró una estacionalidad moderada, una tendencia importante y la menor volatilidad relativa. Terrestre presentó la tendencia de crecimiento más fuerte de las cuatro series nacionales (0.818) y el mayor impacto de la pandemia. Marítima fue la más estacional y volátil de las vías, con resultados condicionados por cambios metodológicos en la clasificación de los viajeros. La serie total, que agrega Aérea y Terrestre bajo el criterio de comparabilidad, presentó una tendencia casi tan dominante como la de Terrestre (0.80 frente a 0.818). Entre las regiones, América del Centro combinó el mayor crecimiento histórico con la mayor volatilidad y la

recuperación más débil frente a 2019, mientras que América del Norte y Europa, con crecimientos más moderados, ya habían superado su nivel de 2019 en 2024.

Las transformaciones y diferenciaciones permitieron alcanzar estacionariedad antes de ajustar los modelos: Aérea y Terrestre no necesitaron transformación logarítmica y alcanzaron estacionariedad con una diferencia regular; Total y Marítima sí necesitaron `log1p`, con una diferencia estacional en el caso de Total y dos diferencias regulares en el caso de Marítima, la que requirió mayor grado de diferenciación de las cuatro.

Los parámetros ARIMA/SARIMA fueron propuestos mediante ACF, PACF y pruebas de estacionariedad, y posteriormente se compararon diferentes candidatos con AIC, BIC y diagnóstico de residuos. Además, se evaluaron variantes de Holt-Winters, suavizamiento exponencial y Seasonal Naive bajo el mismo conjunto de prueba en las siete series, y Prophet en las seis series de vías y regiones (no disponible en el entorno usado para la serie total).

El mejor modelo fue distinto para cada serie: suavizamiento exponencial para Aérea, Prophet para Terrestre, Holt-Winters para Marítima, Holt-Winters amortiguado —entrenado sobre la ventana previa al choque sanitario— para la serie total (con el SARIMA $M1(0,0,0)(0,1,1)_{12}+c$ como alternativa casi equivalente), suavizamiento exponencial para América del Centro y América del Norte, y ARIMA(1,0,1) para Europa. Los resultados confirman que la selección de algoritmo debe hacerse según las características de cada serie y no de forma genérica. La autocorrelación presente en los residuos de Aérea y Terrestre indica que sus predicciones todavía pueden mejorarse, mientras que Marítima y Total sí alcanzaron residuos de prueba sin autocorrelación significativa; el caso de América del Norte, cuyo SARIMA pasó los diagnósticos de entrenamiento pero produjo un pronóstico explosivo, añade una advertencia adicional sobre la necesidad de validar siempre fuera de muestra.

Finalmente, los modelos pueden apoyar la planificación de INGUAT, especialmente para anticipar meses de mayor flujo, identificar vías y regiones con crecimiento importante, y evaluar la sensibilidad ante choques externos. Su uso debe complementarse con actualizaciones frecuentes, con una mejora en la consistencia del registro marítimo, con el seguimiento de la recuperación regional frente a los niveles de 2019, y con la lección más general de este análisis: ante un choque estructural como la pandemia, conviene contrastar explícitamente modelos entrenados antes y después del evento, y validar siempre el desempeño fuera de muestra, en vez de asumir que un buen ajuste dentro del entrenamiento —o usar toda la información disponible— es siempre la mejor opción.

Anexo. Candidatos ARIMA y SARIMA evaluados por región

Se muestran los candidatos comparados para cada región antes de seleccionar el modelo final (sección 5.5–5.7). La selección no se basó únicamente en el menor BIC: también se exigió que los residuos no conservaran autocorrelación significativa, lo que explica por qué algunos modelos con BIC menor fueron descartados. Todos los candidatos listados convergieron correctamente.

Tabla A1. Candidatos para América del Centro

Modelo	AIC	BIC	p de Ljung-Box
SARIMA(1,1,1)(1,1,0)[12]	50.59	61.78	0.84
SARIMA(0,1,1)(0,1,1)[12]	58.69	67.05	<0.01
SARIMA(1,1,1)(0,1,1)[12]	60.62	71.77	<0.01

Modelo	AIC	BIC	p de Ljung-Box
SARIMA(2,1,1)(0,1,1)[12]	61.79	75.73	<0.01
SARIMA(1,1,2)(0,1,1)[12]	63.08	76.97	<0.01
ARIMA(0,1,1)	83.48	89.42	1.00
ARIMA(1,1,0)	83.82	89.78	1.00
ARIMA(1,1,1)	84.89	93.79	0.98
ARIMA(2,1,1)	83.40	95.28	0.98

Tabla A2. Candidatos para América del Norte

Modelo	AIC	BIC	p de Ljung-Box
SARIMA(1,1,2)(0,1,1)[12]	373.44	387.33	0.01
SARIMA(0,1,1)(0,1,1)[12]	381.90	390.26	0.04
SARIMA(2,1,1)(0,1,1)[12]	377.16	391.10	0.01
SARIMA(1,1,1)(1,1,0)[12]	382.00	393.18	0.75
SARIMA(1,1,1)(0,1,1)[12]	383.44	394.59	0.02
ARIMA(0,1,1)	433.63	439.57	0.44
ARIMA(1,1,0)	435.59	441.55	0.45
ARIMA(1,1,1)	435.41	444.32	0.35
ARIMA(2,1,1)	433.05	444.93	0.18

Tabla A3. Candidatos para Europa

Modelo	AIC	BIC	p de Ljung-Box
SARIMA(1,0,1)(0,1,1)[12]	313.84	325.02	<0.01
SARIMA(1,0,1)(1,1,0)[12]	315.61	326.83	<0.01
SARIMA(2,0,1)(0,1,1)[12]	313.18	327.16	0.02
SARIMA(1,0,2)(0,1,1)[12]	313.64	327.58	<0.01
ARIMA(1,0,1)	360.86	372.76	0.87
ARIMA(2,0,1)	359.80	374.68	0.20
ARIMA(1,0,0)	366.63	375.58	0.71
SARIMA(0,0,1)(0,1,1)[12]	418.43	426.81	<0.01
ARIMA(0,0,1)	471.67	480.60	<0.01

Respuestas

a. Para cada categoría seleccionada

Serie total de visitantes internacionales

Esta categoría tiene una sola serie (la suma de todas las vías, sin la etiqueta "Guatemala"), así que las cuatro preguntas se responden con sus propios valores en vez de comparar contra otras series de la misma categoría.

- **i. Estacionalidad:** sí presenta, con una fuerza estacional de **0.46** sobre el entrenamiento completo, que sube a **0.73** al excluir el choque de 2020 — un nivel similar al de la vía Marítima y por debajo del de América del Norte y Europa (~0.88–0.89). (*sección 3.1*)
- **ii. Tendencia de crecimiento:** sí presenta, con una fuerza de **0.80** sobre el entrenamiento completo (0.88 al excluir el choque), equivalente a un crecimiento interanual de ≈7%. Es un valor cercano al más alto de las otras dos categorías (Terrestre 0.818, Europa 0.81), aunque no son estrictamente comparables punto a punto: Total usa una ventana pre-choque especial y vías/regiones no. (*sección 3.1*)
- **iii. Volatilidad:** coeficiente de variación de **0.47** (desviación estándar 74,176 / media 156,388, sobre 2009–2026), un nivel intermedio entre Terrestre (0.46) y Marítima (1.15). (*sección 1*)
- **iv. Impacto de la pandemia:** la caída más profunda de las tres categorías — el índice 2019 = 100 baja a **22.73 en 2020** (–77.3%, frente a –75.23% de Terrestre y –74.43% de América del Centro, las caídas mayores de las otras dos categorías). La recuperación observada también es la más sólida de las que sí reportan un índice comparable: en 2024 ya llega a **134.82** (+34.8% sobre 2019) y en 2025 sube a 138.02, por encima de América del Norte (+33.56%) y Europa (+17.98%); las vías no reportan un índice de recuperación equivalente. El mejor modelo (Holt-Winters amortiguado entrenado antes del choque) reproduce esta trayectoria con un error de apenas 8.7% (MAPE) en 2024–2026. (*secciones 1.1 y 6.1*)

Vías de ingreso

- **i. ¿Cuál presenta mayor estacionalidad? Marítima**, con una fuerza estacional de **0.641** (Aérea 0.384, Terrestre 0.409). (*sección 7.1*)
- **ii. ¿Cuál presenta mayor tendencia de crecimiento? Terrestre**, con una fuerza de tendencia de **0.818** y la mayor pendiente mensual relativa antes de 2020 (≈0.87%). (*sección 7.1*)
- **iii. ¿Cuál presenta mayor volatilidad? Marítima**, con un coeficiente de variación de **1.15**, muy por encima de Terrestre (0.46) y Aérea (0.31). (*sección 7.1*)
- **iv. ¿Cuál fue la más afectada por la pandemia? Terrestre**, con una caída de **75.23%** entre 2019 y 2020 (Aérea –72.80%, Marítima –67.89%). (*sección 7.1*)

Regiones geográficas

- **i. ¿Cuál presenta mayor estacionalidad? América del Norte**, con una fuerza estacional pre-2020 de **0.89**, muy cerca de Europa (0.88); América del Centro queda más atrás (0.69). (*sección 7.2*)
- **ii. ¿Cuál presenta mayor tendencia de crecimiento? América del Centro**, con un crecimiento anual compuesto de **9.83%** entre 2009 y 2019, muy por encima de América del Norte (3.81%) y Europa (2.33%). (*sección 7.2*)
- **iii. ¿Cuál presenta mayor volatilidad? América del Centro** también, con una volatilidad interanual pre-2020 de **14.49%**, frente a 12.74% en Europa y 11.98% en América del Norte. (*sección 7.2*)

- **iv. ¿Cuál fue la más afectada por la pandemia?** Las tres cayeron de forma muy similar en 2020 (entre -71.83% y -74.43%), lo que confirma un choque generalizado más que regional; en términos estrictos la más golpeada fue **América del Centro** (-74.43%). La diferencia real aparece en la recuperación: para 2024 América del Norte (+33.56%) y Europa (+17.98%) ya habían superado su nivel de 2019, mientras que **América del Centro seguía 34.87% por debajo** — la única de las tres que aún no se recuperaba. (sección 7.2)

b. En general

i. ¿Qué descubrimientos serían más útiles para que INGUAT tome decisiones?

1. **Terrestre concentra el mayor volumen, el mayor crecimiento estructural y también el mayor impacto de la pandemia**, con América del Centro —que ingresa mayoritariamente por esa vía— todavía por debajo de su nivel de 2019 en 2024. Es el canal y el mercado prioritarios para inversión en infraestructura fronteriza y estrategias de recuperación.
2. **La conectividad y la planificación de recursos deben diferenciarse por canal y por región de origen.** Terrestre/América del Centro y Aérea/América del Norte y Europa son, en la práctica, los mismos dos patrones de acceso vistos desde ángulos distintos (sección 0.6), y diciembre es sistemáticamente el mes de mayor flujo en las tres vías.
3. **La recuperación debe medirse contra el nivel de 2019, no solo contra el fondo de la pandemia.** Con ese criterio, América del Norte y Europa ya se habían recuperado en 2024 y América del Centro no, pese a haber tenido el mayor crecimiento histórico y ser el mercado más volátil.
4. **La vía Marítima y, en general, cualquier serie con cambios de definición, requieren mejorar la consistencia del registro** antes de poder usarse con la misma confianza que Aérea o Terrestre para la toma de decisiones.
5. **Aérea, por su menor volatilidad, permite una planificación de capacidad más predecible** que Terrestre o Marítima, lo que la hace un canal atractivo para fortalecer con nuevas rutas y alianzas con aerolíneas, particularmente hacia Estados Unidos, el segundo país de origen en volumen.
6. **Las proyecciones deben tratarse como rangos de planificación y actualizarse con cada nuevo mes de datos**, dado que la recuperación posterior a 2020 todavía está en curso y su ritmo difiere por vía y por región.