

Informe narrativo — Laboratorio 2: Deep Learning y Catch22

Universidad del Valle de Guatemala

VIANKA CASTRO -23201 SEBASTIÁN GARCÍA -22291 RICARDO GODÍNEZ -23247

Este documento recorre, en el orden en que se trabajaron, los cinco notebooks de [L02_DL_series/notebooks/](#). La idea es contar la historia completa del laboratorio de principio a fin: primero el Ejercicio 1 (modelar con LSTM las series ya construidas en el Laboratorio 1 y compararlas contra los modelos clásicos), y después el Ejercicio 2 (caracterizar esas mismas series con Catch22, agruparlas por similitud, e incorporar esas características a un nuevo modelo LSTM). En su mayoría se reutiliza el texto que el propio equipo escribió en las celdas markdown de cada notebook.

Notebook 01 — [01_lstm_series_geograficas.ipynb](#)

Este notebook arranca retomando, a modo de referencia, el análisis completo del Laboratorio 1: calidad de datos, comportamiento temporal, composición geográfica, vías y fronteras de ingreso, y el ajuste de modelos clásicos (ARIMA/SARIMA, Prophet, Holt-Winters, suavizamiento exponencial simple y seasonal naïve) sobre las tres vías de ingreso y las tres regiones con mayor volumen. Esa parte queda explícitamente marcada como "laboratorio anterior para comparación" y no se desarrolla aquí en detalle — lo que interesa narrar es lo que viene después, que es el trabajo nuevo del Laboratorio 2.

Ejercicio 1 — Modelos LSTM

Se seleccionan las series de América Del Centro y Europa. La primera representa la región con mayor volumen, crecimiento y volatilidad antes de la pandemia. Europa permite contrastar el desempeño de LSTM con la región donde ARIMA había obtenido el mejor resultado en el análisis anterior.

La comparación conserva exactamente la división cronológica utilizada anteriormente: enero de 2009 a marzo de 2021 para entrenamiento y abril de 2021 a junio de 2026 para prueba.

1.1 — Conjuntos de entrenamiento y prueba.

El conjunto de prueba permanece completamente aislado durante el tuneo. Los últimos 24 meses del entrenamiento se emplean como validación cronológica. Esta validación incluye el comienzo de la pandemia y permite seleccionar parámetros sin consultar los 63 meses de prueba.

La partición no se realiza de forma aleatoria, porque mezclar meses pasados y futuros produciría fuga de información. El escalador también se ajusta únicamente con la porción utilizada para entrenar cada modelo.

1.2 — Configuraciones y tuneo de parámetros.

Se evalúan cuatro configuraciones por región. El tuneo modifica la longitud de la ventana, el número de unidades, la profundidad de la red, dropout, tasa de aprendizaje y tamaño de lote.

Cada observación de entrada contiene únicamente meses anteriores. La salida corresponde al siguiente mes. Durante la validación, el pronóstico se genera recursivamente para reproducir el uso real del modelo en un horizonte de varios meses.

El criterio detrás de cada hiperparámetro quedó documentado así:

- **Ventanas de 12 y 24 meses.** Una ventana de 12 meses permite que la red observe un ciclo anual completo. La ventana de 24 meses permite comparar el comportamiento de dos ciclos, aunque reduce la cantidad de ejemplos disponibles para entrenar.
- **32 y 64 unidades LSTM.** Treinta y dos unidades representan un modelo relativamente pequeño. Sesenta y cuatro unidades aumentan la capacidad para aprender relaciones más complejas, pero también incrementan el riesgo de sobreajuste.
- **Una y dos capas.** Una capa ofrece una arquitectura sencilla. Dos capas permiten aprender representaciones temporales más profundas, aunque requieren regularización y más datos.
- **Dropout entre 0.00 y 0.30.** Su objetivo es reducir el sobreajuste, especialmente en las configuraciones con más unidades o capas.
- **Learning rate de 0.0010 y 0.0005.** El valor 0.0010 permite una actualización moderada de los pesos. El valor 0.0005 se utiliza en la arquitectura más profunda para actualizaciones más pequeñas y estables.
- **Batch de 8 y 16.** Se utilizaron lotes pequeños porque el conjunto contiene solamente 147 meses de entrenamiento.


El espacio de búsqueda se mantuvo deliberadamente pequeño. Probar demasiadas combinaciones con una serie corta puede terminar ajustando los parámetros al período de validación en lugar de identificar una estructura que se generalice.

Los últimos 24 meses del conjunto de entrenamiento se reservaron como validación cronológica. Para cada configuración se pronosticaron esos 24 meses de forma recursiva. El modelo con menor RMSE de validación fue seleccionado para cada región.

El resultado del tuneo: **América del Centro** eligió la configuración LSTM-C (ventana 12, 32 unidades, 2 capas, dropout 0.20, lr 0.0010, batch 8, RMSE de validación $\approx 116,282$) y **Europa** eligió LSTM-A (ventana 12, 32 unidades, 1 capa, dropout 0.00, lr 0.0010, batch 8, RMSE de validación $\approx 5,737$).

1.3 — Predicción con los mejores modelos.

Después del tuneo, cada arquitectura seleccionada se reentrena con los 147 meses del conjunto de entrenamiento. Se utiliza el número de épocas que produjo la menor pérdida de validación, con un mínimo fijo de cinco épocas para evitar un ajuste insuficiente al incorporar todo el entrenamiento. Esta regla se establece antes de consultar la prueba. La predicción de los 63 meses de prueba se realiza de forma recursiva, es decir, cada pronóstico se incorpora a la ventana utilizada para predecir el mes siguiente.



1.4 — Comparación y respuestas.

La comparación con el laboratorio anterior se realiza dentro de cada serie y sobre el mismo conjunto de prueba. Se utilizan MAE y RMSE en unidades originales. Para decidir cuál serie fue predicha mejor se utiliza nRMSE y sMAPE, porque los errores absolutos de regiones con escalas distintas no son directamente comparables.

Región	Modelo anterior	MAE anterior	RMSE anterior	MAE LSTM	RMSE LSTM	Mejora MAE	Mejora RMSE
América del Centro	Suavizamiento exponencial	108,284.61	120,341.06	73,245.90	87,153.20	+32.36%	+27.58%
Europa	ARIMA(1,0,1)	6,420.06	7,823.86	8,185.98	9,371.32	-27.51%	-19.78%
Región	nRMSE sMAPE MASE estacional						
América del Centro	54.11%	53.82%	1.79				
Europa	79.88%	103.88%	4.70				

Con esas métricas comparables entre escalas, América del Centro resultó la serie predicha relativamente mejor por la LSTM. El criterio de decisión y su matiz quedaron así:

El mejor modelo LSTM de cada serie se selecciona con la validación interna y no con el conjunto de prueba. La comparación final utiliza exactamente los mismos meses de prueba y las mismas métricas

del laboratorio anterior. Esta igualdad de condiciones permite atribuir la diferencia observada al método de modelado y no a un cambio en los datos evaluados.

Un resultado inferior de LSTM no implica que las redes recurrentes sean inadecuadas en general. Estas series contienen únicamente 147 meses para entrenamiento y una ruptura estructural cerca del final. Las LSTM suelen beneficiarse de conjuntos más extensos y de variables externas, por ejemplo conectividad aérea, restricciones de movilidad, indicadores económicos y calendarios de eventos.

Notebook 02 — 02_lstm_serie_total.ipynb

Con el mismo enfoque del notebook anterior, pero ahora sobre la **serie total internacional**, este notebook construye la serie desde cero a partir de la base cruda y entrena tres configuraciones de LSTM distintas.

1. Carga de los datos y construcción de la serie

Antes de modelar se resuelven dos quiebres de comparabilidad de la fuente:

Se aplican **dos** filtros, ambos por comparabilidad temporal y no por criterio conceptual. La fuente cambia de metodología en 2023 y sin estos filtros la serie mezclaría universos distintos:


1. **Tipo de Viajero** $\in$ {Turista, Excursionista}. Se excluyen **Crucelistas** (deja de reportarse desde 2023) y **Viajero** (se reclasifica y pierde ~70% de nivel en 2023). Ninguno de los dos quiebres corresponde a un cambio real del turismo.
2. **País $\neq$ Guatemala**. La etiqueta **Guatemala** (residentes que reingresan al país) representa entre 34% y 48% del total hasta 2022 y **desaparece por completo desde enero de 2023**, sin ser reabsorbida por ninguna otra agrupación.

Con esos filtros aplicados, la serie mensual queda con 210 observaciones (enero 2009 a junio 2026), reindexada a frecuencia mensual regular.

2. División 70–30 de los datos (en orden cronológico)

Al tratarse de una serie de tiempo, la partición **no puede ser aleatoria**: se toma el 70% inicial de los meses para entrenamiento y el 30% final para prueba. Mezclar meses futuros en el entrenamiento produciría fuga de información y una evaluación optimista.

La partición resultó en 147 meses de entrenamiento y 63 de prueba, con la particularidad de que la media del conjunto de prueba es notablemente más alta que la de los últimos 12 meses de entrenamiento — el modelo tiene que atravesar un cambio de régimen.



3. Preparación de la serie para LSTM

A diferencia de un SARIMA, una LSTM no recibe la serie directamente: hay que convertirla en un problema de aprendizaje supervisado.

1. **Escalado.** Las compuertas de una LSTM usan activaciones `sigmoid/tanh`, que saturan fuera de un rango acotado, así que conviene llevar la serie a `[0, 1]` con `MinMaxScaler`. El escalador se ajusta **solo con entrenamiento** — usar la prueba para ajustarlo sería fuga de información.
2. **Ventanas deslizantes.** Cada observación de entrada x son los `look_back` meses previos, y la salida y es el mes siguiente.
3. **Pronóstico recursivo.** Para evaluar sobre la prueba se replica lo que hace `SARIMAX.get_forecast()`: se pronostica un paso, esa predicción se realimenta como parte de la ventana de entrada, y así sucesivamente hasta cubrir todo el horizonte. Ningún valor real de la prueba se usa como entrada.


4-7. Los tres modelos

Modelo 1 — LSTM simple. Configuración base: una sola capa LSTM de 50 unidades, ventana de 12 meses (un ciclo estacional completo) y optimizador Adam con la tasa de aprendizaje por defecto.

Modelo 2 — LSTM apilada con regularización. Deliberadamente distinta del Modelo 1 en varios ejes a la vez: dos capas LSTM apiladas (64 → 32 unidades) más una capa densa oculta, `Dropout(0.2)` entre capas, ventana de 6 meses en vez de 12, y optimizador RMSprop con una tasa de aprendizaje menor.

Modelo 3 — tuneo automático con `keras_tuner`. Los Modelos 1 y 2 fueron dos configuraciones elegidas a mano. Aquí se automatiza la búsqueda sobre número de capas, unidades por capa, dropout, tasa de aprendizaje y tamaño de lote. La búsqueda no puede evaluarse contra el conjunto de prueba — eso sería la misma fuga que evitar mezclar meses futuros en el entrenamiento. En su lugar se separan los últimos 24 meses del entrenamiento como ventana de validación.

Modelo	Configuración	look_back	MAE	RMSE	MAPE %
Modelo 1 — LSTM simple	1 capa (50u), Adam	12	111,555.69	126,235.75	47.48
Modelo 2 — LSTM apilada	2 capas (64,32u) + dropout, RMSprop	6	124,901.84	141,949.69	52.97
Modelo 3 — tuneado	dropout=0.2, lr=0.01, 1 capa (50u)	12	—	140,243	54.7



8.1 Lectura de los resultados

El **Modelo 1** (una sola capa LSTM de 50 unidades, `look_back=12`, Adam) es el mejor de los tres pese a ser la configuración más simple.

El **Modelo 2** queda un 12.4% peor en RMSE. Con apenas ~135-141 secuencias de entrenamiento disponibles, duplicar la profundidad y agregar regularización no ayuda — es el patrón clásico de sobre-parametrizar una serie corta.

El resultado más informativo es el del **Modelo 3 (tuneado)**: `keras_tuner` evaluó 15 combinaciones y escogió una arquitectura casi idéntica a la del Modelo 1, pero con `dropout=0.2` y una tasa de aprendizaje diez veces mayor. Esa combinación ganó en la ventana de validación interna, pero termina peor en la prueba real — prácticamente empatada con el Modelo 2 y por debajo de la configuración manual del Modelo 1. La búsqueda automática no es inmune a optimizar para el tramo de validación en lugar de generalizar: los últimos 24 meses de entrenamiento usados para puntuar los hiperparámetros caen justo sobre el quiebre de fuente de 2023, un tramo con una dinámica particular que no necesariamente representa el resto del horizonte de prueba.

Entre las tres configuraciones evaluadas, la LSTM simple del Modelo 1 es la más adecuada para esta serie. Con una serie de apenas ~147 observaciones de entrenamiento y un quiebre de metodología a la mitad del horizonte de prueba, un modelo de pocos parámetros — sea SARIMA o una LSTM de una sola capa — generaliza mejor que arquitecturas más grandes.

Con el Ejercicio 1 cerrado, el laboratorio cambia de pregunta: en vez de pronosticar, se busca **caracterizar y comparar** las series entre sí. Este notebook es el punto de partida del Ejercicio 2 y responde los incisos 2.1–2.4.

1. Idea detrás de Catch22

Catch22 significa **22 CAnonical Time-series CHaracteristics**. Su propósito es transformar una serie temporal completa en un vector corto de 22 medidas que resume propiedades dinámicas como autocorrelación, predictibilidad, distribución de valores, cambios sucesivos, valores atípicos y escalamiento de las fluctuaciones.

Estas 22 características fueron seleccionadas de una biblioteca mucho mayor para obtener una representación informativa, poco redundante e interpretable, pero mucho más rápida de calcular. Gracias a esta representación, series con escalas y comportamientos diferentes pueden compararse dentro de un mismo espacio de características.


2. Definición de las siete series

Se reutilizan las decisiones metodológicas del Laboratorio 1:

- **Total internacional:** turistas y excursionistas, excluyendo País = Guatemala.
- **Aérea:** turistas y excursionistas por vía aérea.
- **Terrestre:** turistas y excursionistas por vía terrestre.
- **Marítima:** todos los tipos de viajero por vía marítima, según la decisión tomada en L1.
- **América del Centro, América del Norte y Europa:** turistas y excursionistas clasificados mediante la columna Región dos.

Todas las series deben compartir un calendario mensual de enero de 2009 a junio de 2026.


Tras cargarlas y validarlas (misma longitud, fechas consecutivas, sin valores faltantes ni series constantes), así se ven las siete series una vez normalizadas solo para comparar su forma:



4-5. Extracción y estandarización

Se ejecuta `catch22` una vez por serie. El resultado se organiza en una matriz donde cada fila representa una serie temporal y cada columna una característica.

Las 22 características tienen rangos diferentes. Por ello se aplica `StandardScaler` a la matriz completa, columna por columna. La estandarización se realiza **después** de extraer `catch22` y antes de cualquier PCA, clustering o análisis de distancias.



El mapa de calor permite verificar visualmente que las siete series presentan perfiles diferentes. La interpretación formal de grupos, distancias y componentes principales corresponde al notebook posterior de agrupamiento.

6-7. Guardado y resultado

Se guardan tres archivos: `series_mensuales.csv` (calendario común y las siete series), `catch22_features.csv` (matriz original de 7×22) y `catch22_features_scaled.csv` (matriz estandarizada de 7×22).

Se construyeron siete series mensuales con 210 observaciones cada una. Para cada serie se calcularon exactamente 22 características `catch22`, produciendo una matriz de **7 filas × 22 columnas**. Los tres CSV quedaron listos para el análisis posterior de PCA, clustering, correlaciones y distancias.

Notebook 04 — 04_agrupamiento_series.ipynb

Con la matriz de características lista, este notebook es el corazón analítico del Ejercicio 2: responde los incisos 2.5 a 2.13, combinando cinco análisis comparativos con la interpretación de cada uno.


¿Qué series de tiempo se parecen entre sí cuando se las representa mediante sus 22 características `catch22`, y qué revela esa similitud que no era visible en el análisis exploratorio tradicional?

Todos los análisis comparativos de este notebook se realizan sobre la **matriz estandarizada** de 7×22 . Usar la matriz sin escalar haría que las características con rangos más amplios dominaran las

distancias y las componentes principales.

Componentes principales

El PCA proyecta la matriz estandarizada sobre un número reducido de componentes que concentran la mayor parte de la varianza. Con siete series y veintidós características hay más variables que observaciones, por lo que el número máximo de componentes con varianza no nula es **seis**.



Podemos ver que para el eje horizontal (que es el PC1) que es la que nos ayuda a ver que tan bien se porta la serie. En la derecha podemos ver las series que se portan de manera más fluctuante, como lo es la vía marítima que gracias al laboratorio pasado pudimos ver que era la vía de entrada con más matices y un frenado. Luego la vía aérea se ve que no es tan sencilla de predecir pero eso lo atribuimos a que fue la vía que más se vio afectada durante la emergencia sanitaria del 2020. De igual manera los visitantes de Europa son los que más fluctúan por las mismas razones. Las series que se mantienen más predecibles son la cantidad de visitantes internacionales y la vía más fácil de interpretar es la vía terrestre.

El eje vertical nos indica si las series mantienen su promedio o se despegan mucho de este. Podemos ver que los visitantes internacionales, la vía terrestre, aérea y los visitantes de Centroamérica son los que se mantienen sobre su promedio. Mientras que los visitantes de América del Norte y Europa fluctúan mucho.

Agrupamiento


Se aplica un algoritmo de agrupamiento sobre la matriz estandarizada para obtener una partición explícita de las series. Con solo siete observaciones el rango razonable es estrecho: valores de k entre 2 y 4.

El coeficiente de silueta llevó a elegir $k=3$: Grupo 0 = {aérea, marítima}, Grupo 1 = {total_internacional, terrestre, américa_centro}, Grupo 2 = {américa_norte, europa}.

Gracias a este agrupamiento podemos ver cuáles series son las que más se relacionan gracias a sus características de Catch22. El grupo más correlacionado es el de la serie de la vía terrestre y los visitantes de América del Centro. Lo que tiene sentido ya que es más común que los visitantes que quedan en una ubicación geográfica muy cercana entren por la vía terrestre. Luego el grupo de América del Norte y Europa. Estos posiblemente fueron agrupados por cómo se comportan de

manera similar al momento de que sus habitantes visitan Guatemala. Y por último el total internacional y terrestre nos dice que la mayoría de personas internacionales que llegan a Guatemala lo hacen por la vía terrestre.

Mapa de calor de características




Gracias al mapa de calor nos deja ver lo que caracteriza a cada grupo.

1. El grupo 1 (total internacional, terrestre y américa del centro) son series con tendencia clara y buena memoria. El pasado ayuda a predecir el futuro de estas.
2. El grupo conformado por américa del norte y europa suben y bajan sin quedarse en un lado fijo. Son más desordenadas y sus rachas son cortas.
3. Aéreo y marítimo no tienen un perfil común, se agruparon por descarte.

Matriz de correlaciones entre características

Con solo siete series como observaciones, la correlación entre pares de características es inestable — sirve para detectar redundancia gruesa, no para afirmar relaciones precisas. Aun así, algunos pares resultaron casi redundantes ($r \approx 0.99$), por ejemplo dos formas distintas de medir "cuánto tarda una serie en olvidar" (`IN_AutoMutualInfoStats_40_gaussian_fmml` vs. `CO_FirstMin_ac`, $r=0.993$).

Mapa de distancias entre series



La matriz muestra tres niveles de cercanía:

1. 2.36 — terrestre con américa_centro. Están casi al doble de cerca que cualquier otra pareja.
2. 4.4 a 4.9 — américa_norte con europa, y total_internacional con terrestre.
3. 7 a 10.5 — todo lo que tenga que ver con marítima, que está a 7 o más de absolutamente todas.

Lo primero tiene una explicación material muy concreta: los centroamericanos entran por tierra. Así que terrestre y américa_centro son, en buena medida, la misma gente contada de dos maneras distintas. Y catch22 lo detecta sin que nadie le haya dicho de dónde viene cada serie.

Interpretación — incisos 2.6 a 2.13

Series más similares (2.7).

Terrestre y américa_centro son las más relacionadas. Están a 2.36 de distancia, cuando la siguiente pareja más cercana (américa_norte con europa) está a 4.41 — casi el doble. Y lo importante es que las tres evidencias apuntan al mismo lado: son la pareja número 1 tanto midiendo en las 22 dimensiones como en el plano del PCA, y además el agrupamiento las dejó juntas. Cuando tres

métodos distintos coinciden, el resultado es sólido. De hecho, el orden completo de las 21 parejas coincide casi perfectamente entre los dos criterios (correlación de Spearman de 0.923).

Características más discriminantes (2.8).

Las que más ayudan a diferenciar las series son `CO_Embed2_Dist_tau_d_expfit_meandiff` (estructura del recorrido), `CO_HistogramAMI_even_2_5` (cuánto ayuda el pasado a predecir), `CO_FirstMin_ac` (cuánto tarda en olvidar), `SP_Summaries_welch_rect_area_5_1` (peso del movimiento lento de fondo) e `IN_AutoMutualInfoStats_40_gaussian_fmfi`.

Grupos naturales (2.9).

Cada grupo tiene una firma clara: **G1** (total_internacional, terrestre, américa_centro) son las predecibles — mucho peso en el movimiento lento de fondo, el pasado ayuda bastante a predecir, poco desorden y error de pronóstico bajo. **G2** (américa_norte, europa) son las desordenadas pero simétricas — alto desorden, valores extremos marcados, oscilan sin quedarse de un lado. **G0** (aérea, marítima) es el grupo que no es grupo: ciclos largos y periodicidad marcada pero poca información compartida con su propio pasado — se repiten pero no son predecibles. G1 y G2 son grupos de verdad: sus miembros están mucho más cerca entre sí que del resto. G0 no.

Correspondencia con las categorías conocidas (2.10).

No. La categoría administrativa casi no dice nada sobre cómo se comporta la serie. El índice Rand ajustado entre la categoría y el agrupamiento es de 0.140, donde 1 sería coincidencia perfecta y 0 lo que se esperaría por puro azar. Ninguna categoría queda intacta: las tres vías se reparten entre dos grupos, y las tres regiones también. Las tres vías de ingreso son más distintas entre sí que dos series tomadas al azar — tiene sentido si lo piensas: aérea, terrestre y marítima son canales con lógicas completamente distintas (turismo de larga distancia, flujo fronterizo regional, cruceros).

Serie atípicas (2.11).

Marítima es la más atípica, sin discusión. Es la primera en las dos medidas: su vecino más cercano está a 7.08 (cuando el promedio ronda 4.4) y está a 6.84 del centro de todas. Pero hay un segundo caso más interesante: aérea tiene una silueta de -0.00 — está justo en la frontera, confirmación cuantitativa de que G0 no es un grupo real.

Lo que hace atípica a una serie es tener meses en cero, no ser volátil. La correlación con la volatilidad es apenas 0.39, mientras que con los meses en cero llega a 0.69. Marítima tiene 27 meses en cero de 210 — un 13% del período — y eso le deforma toda la firma.

Contraste con el Laboratorio 1 (2.12).

Las regiones sí difieren, y la razón es que en el Lab 1 la estacionalidad se calculó excluyendo 2020, y aquí se usó el período completo. La pandemia destruye más de la mitad de la estacionalidad medible: el patrón anual sigue ahí, pero 2020 mete tanto ruido que las medidas estándar dejan de verlo.

Y ahora lo importante: correlacionando cada descriptor clásico con los ejes del PCA de catch22, el primer eje del PCA resultó ser, literalmente, la fuerza de tendencia al revés (correlación -1.00). Catch22 redescubrió por su cuenta el descriptor más importante del análisis clásico, sin que nadie se lo dijera, partiendo solo de 22 medidas automáticas. Y hay más estructura: la estacionalidad y la

autocorrelación anual viven en el tercer eje, no en los dos primeros — por eso el plano bidimensional no las muestra.

Hallazgos nuevos (2.13).

Hallazgo 1 — Catch22 agrupa distinto que el análisis clásico. Repitiendo el agrupamiento solo con los seis descriptores tradicionales el resultado es otro (Rand ajustado de 0.140 entre ambos). El análisis clásico aísla a marítima por su volatilidad; catch22 la agrupa con aérea y en cambio separa total_internacional de las vías.

Hallazgo 2 — Cuatro características miden algo que el análisis clásico no ve:

`SB_BinaryStats_diff_longstretch0`, `DN_HistogramMode_5`, `SB_MotifThree_quantile_hh` y `CO_trev_1_num` tienen correlación baja con todos los descriptores tradicionales, y entre las cuatro aportan el 17.2% del peso de los ejes del PCA.

Hallazgo 3 — La asimetría entre subidas y bajadas. `CO_trev_1_num` es la única característica que aparece entre las que mejor separan a los grupos y entre las que el análisis clásico no captura. Mide si una serie sube de forma distinta a como baja — algo que ni la descomposición, ni la ACF, ni el coeficiente de variación registran, porque todos son simétricos por construcción. Es información genuinamente nueva y además discrimina.

Notebook 05 — `05_lstm_catch22.ipynb`

El último notebook cierra el laboratorio uniendo los dos ejercicios: usa las características Catch22 del notebook 03 para enriquecer una LSTM que pronostica la serie total, y compara el resultado contra el mejor modelo del notebook 02.


Se modela `total_internacional` y se compara con el mejor LSTM obtenido previamente para esa misma serie: el Modelo 1 del notebook 2. Se conserva el corte 70/30, una ventana de 12 meses, una LSTM de 50 unidades y Adam. Una ablación global sin Catch22 separa el efecto de usar siete series del aporte de las 22 características.

La comparación se realiza con el mejor modelo de la serie total, no con el menor RMSE absoluto entre todas las series. Los errores de América del Centro, Europa y la serie total no son comparables directamente porque sus escalas son diferentes.

1. Datos y diseño

Cada fila Catch22 describe una serie completa, no un mes. Se usa una **LSTM global**: cada muestra contiene 12 rezagos de una de las siete series y su firma Catch22 repetida en esos pasos. La entrada enriquecida tiene 23 canales (valor + 22 características); la repetición aporta contexto estático, no una variable mensual.


Esto da 945 muestras de entrenamiento (7 series × 135 ventanas cada una). Se entrenaron dos modelos: uno sin Catch22 (ablación, 200 épocas, pérdida final 0.0078) y otro con Catch22 (47 épocas con early stopping, pérdida final 0.0316).



2. Pronóstico recursivo y comparación

Como en el notebook 2, los 63 meses se pronostican recursivamente: cada predicción se realimenta y ningún valor real futuro entra como rezago. La referencia es el **Modelo 1**, seleccionado en el notebook 2 como el mejor LSTM de *total_internacional*: MAE 111,555.69; RMSE 126,235.75; MAPE 47.48%.

Los modelos geográficos del notebook 1 no se usan como referencia porque predicen series distintas. Aunque América del Centro obtuvo un RMSE absoluto menor, comparar esos valores directamente sería incorrecto debido a las diferencias de escala.



Modelo	Ajuste	Entradas	MAE	RMSE	MAPE %
Global + Catch22	7 series	12 rezagos + 22 Catch22	79,014.63	89,244.22	56.65
LSTM base total — Modelo 1 (notebook 2)	1 serie	12 rezagos	111,555.69	126,235.75	47.48
Global sin Catch22 (ablación)	7 series	12 rezagos	214,230.22	268,277.54	90.73

Conclusión y limitaciones

Catch22 reduce MAE y RMSE frente al mejor LSTM previamente obtenido para la misma serie total, mientras que el MAPE empeora. Por tanto, el resultado es mixto y no representa una mejora uniforme en todas las métricas. La ablación muestra además que el aporte no procede solo de aumentar las ventanas.

- **Elección de la referencia:** se utiliza el Modelo 1 del notebook 2 porque tanto ese modelo como la nueva LSTM con Catch22 pronostican `total_internacional`. Los LSTM geográficos son resultados válidos para sus propias series, pero no son una referencia directa para este objetivo.
- **Perfil transductivo:** la prueba no ajusta pesos ni se usa como rezago, pero el vector Catch22 resume la serie completa; las métricas pueden ser optimistas.
- **Comparación:** frente al modelo base cambian Catch22 y el entrenamiento global. La ablación permite observar por separado el comportamiento del diseño global sin las características.

En números: el modelo global con Catch22 reduce RMSE en 29.3% y MAE en 29.2% frente al Modelo 1 del notebook 2, pero empeora el MAPE en 19.3%. Y frente a la ablación sin Catch22 (mismo diseño global, sin las 22 características), la reducción de RMSE es de 66.7% — la mayor parte de la mejora viene específicamente de la firma Catch22, no solo de entrenar con las siete series a la vez.

Cierre

El laboratorio recorrió dos preguntas distintas sobre las mismas series de visitantes internacionales a Guatemala. El **Ejercicio 1** (notebooks 01 y 02) puso a competir LSTM contra los modelos clásicos del Laboratorio 1, serie por serie: la LSTM ganó en América del Centro y en la serie total, pero perdió contra ARIMA en Europa — un resultado que depende de cuánta historia tiene cada serie y de qué tan cerca del quiebre estructural cae el conjunto de prueba, no de que un enfoque sea universalmente mejor que el otro. El **Ejercicio 2** (notebooks 03 a 05) cambió el objetivo de pronosticar a caracterizar: Catch22 permitió comparar las siete series en un mismo espacio de 22 dimensiones, reveló que la cercanía geográfica (terrestre con `américa_centro`) pesa más que la categoría administrativa (vía de ingreso o región), y que esa misma firma, incorporada como información adicional a una LSTM global, mejora sustancialmente el pronóstico de la serie total frente a entrenar sin ella — aunque no de manera uniforme en todas las métricas.