

Laboratorio 5: clasificación de tweets usando minería de texto

CC3084 - Data Science · Laboratorio 5

Universidad del Valle de Guatemala · Semestre II, 2026

Vianka Castro - 23201

Ricardo Godinez - 23247

Sebastian Bustamante - 22291

Dataset: *Natural Language Processing with Disaster Tweets* (Kaggle)

Repositorio: <https://github.com/Vann06/Data-Science>

Fecha: 28 de agosto de 2026

Resumen ejecutivo

Se analizaron **7,613 tweets etiquetados**, de los cuales 3,271 (43.0%) corresponden a desastres reales. Se construyó un pipeline reproducible de normalización, limpieza, tokenización, eliminación de *stopwords*, lematización y generación de n-gramas. El mejor clasificador fue **Naive Bayes complementario**, con F1 medio de 0.752 en validación cruzada y F1 de 0.781 en la prueba final. VADER mostró mayor negatividad en tweets de desastre real, aunque agregar esa variable al clasificador cambió el F1 en -0.0013 (-0.16%), por lo que no mejoró el modelo.

1. Objetivo y datos

El objetivo fue determinar si el texto de un tweet se refiere a un desastre real (`target=1`) o emplea términos de desastre en un contexto figurado (`target=0`). `train.csv` contiene 7,613 filas y cinco columnas: `id` , `keyword` , `location` , `text` y `target` . `keyword` tiene 61 valores ausentes y `location` tiene 2,533; el texto y la etiqueta no presentan ausencias.




Figura 1. Distribución de los tweets por clase. El desbalance 57/43 es moderado; por ello se empleó F1 como métrica principal sin remuestreo.

Se detectaron 179 filas pertenecientes a 69 grupos de texto repetido, incluidos 18 grupos con etiquetas contradictorias. Esta característica se considera una limitación en la evaluación.




Figura 2. Los tweets de desastre real tienden a ser ligeramente más extensos, aunque las distribuciones se superponen ampliamente.

2. Limpieza y preprocesamiento

El pipeline se implementó en `src/limpieza/` y se ejecutó en `limpieza.ipynb`. El orden fue: (1) conversión a minúsculas y normalización Unicode; (2) expansión de contracciones; (3) eliminación de URL, entidades HTML y emojis; (4) conservación de la palabra de hashtags y menciones mediante flags; (5) sustitución de números por `flagnumero`, distinguiendo `911` con `flagemergencia`; (6) eliminación de puntuación; (7) tokenización con `TweetTokenizer`; (8) eliminación de *stopwords* de NLTK, preservando negaciones; (9) lematización con WordNet y etiqueta gramatical; y (10) generación de unigramas y bigramas.

El sentimiento se calculó posteriormente sobre el texto original, no sobre el texto limpio, porque VADER utiliza puntuación, mayúsculas, negaciones y emoticonos como señales.

ID	Clase	Texto original	Texto procesado
1	Desastre	Our Deeds are the Reason of this #earthquake May ALLAH Forgive us all	deed reason flaghashtag earthquake may allah forgive
4	Desastre	Forest fire near La Ronge Sask. Canada	forest fire near ronge sask canada
5	Desastre	All residents asked to 'shelter in place' are being notified by officers. No other evacuation or shelter in place orders are expected	resident ask shelter place notify officer no evacuation shelter place order expect
31	No desastre	this is ridiculous....	ridiculous
48	Desastre	@bbcmtd Wholesale Markets ablaze http://t.co/IHYXEOHY6C	flagmencion bbcmtd wholesale market ablaze

Tabla 1. Ejemplos auditables del texto antes y después del pipeline.




Figura 3. Los tweets de desastre concentran términos de eventos y cobertura noticiosa, mientras que los no desastres contienen más lenguaje cotidiano o figurado. Palabras presentes en ambas clases, como `fire` o `body`, no son suficientes por sí solas para clasificar.

Nubes de palabras del corpus limpio



Figura 4. Nubes de palabras del corpus limpio. La separación visual apoya el uso de características léxicas, pero también muestra vocabulario compartido.

Los bigramas preservan contexto local en expresiones como `suicide bomber`, `oil spill`, `forest fire` y `body bag`. El análisis posterior a la limpieza mostró que alrededor del 86% de los bigramas aparece una sola vez; por ello se utilizó `min_df=2`. La comparación del notebook `analisis_post_limpieza.ipynb`

obtuvo F1 de 0.746 con unigramas y 0.750 con unigramas+bigramas; la diferencia de aproximadamente 0.005 no fue significativa (prueba pareada, $p = 0.24$), pero el costo de pasar de unas 5,322 a 11,918 características fue aceptable.

Bigramas mas frecuentes por categoria




Figura 5. Bigramas más frecuentes después de excluir flags técnicos.

Bigrama	Frecuencia	Tweets	P(desastre bigrama)
body bag	74	73	0.08
suicide bomber	60	58	1.00
look like	55	55	0.35
youtube video	43	43	0.16
northern california	41	41	1.00
burn building	41	41	0.54
cross body	40	40	0.03
oil spill	39	37	0.97
year old	35	25	0.76
california wildfire	34	34	1.00
suicide bomb	33	32	0.91
mass murder	33	33	0.85

Tabla 2. Frecuencia y probabilidad empírica de desastre de los bigramas más comunes. Estas probabilidades describen asociación en este corpus; no son probabilidades calibradas del clasificador.

5. Modelos de clasificación

Se reservó 20% del corpus como prueba final estratificada (1,523 tweets) y se empleó el 80% restante (6,090 tweets) para seleccionar el modelo mediante validación cruzada estratificada de cinco particiones. TF-IDF se mantuvo dentro de cada Pipeline para evitar fuga de vocabulario. La representación usó `gram_range=(1,2)`, `min_df=2`, `max_df=0.98`, frecuencia sublineal y norma L2.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Naive Bayes complementario	0.800	0.804	0.708	0.752	0.853
Regresion logistica	0.798	0.808	0.695	0.747	0.853
SVM lineal	0.776	0.760	0.702	0.729	0.839
SGD (modified Huber)	0.735	0.693	0.694	0.692	0.796
Linea base	0.570	0.000	0.000	0.000	0.500

Tabla 3. Resultados promedio de validación cruzada. Naive Bayes complementario (`alpha=0.5`) obtuvo el mayor F1.




Figura 6. F1 promedio y una desviación estándar entre particiones.

En la prueba final, el modelo seleccionado obtuvo `accuracy=0.823`, `precision=0.836`, `recall=0.732`, `F1=0.781` y `ROC-AUC=0.869`.




Figura 7. Matriz de confusión: 775 verdaderos negativos, 94 falsos positivos, 175 falsos negativos y 479 verdaderos positivos.

6. Función de clasificación

`clasificar_tweet()` recibe texto sin preprocesar, reutiliza exactamente `src/limpieza/pipeline.py`, transforma el resultado con el TF-IDF ajustado y devuelve la clase legible junto con la probabilidad de desastre. Por ejemplo, *"Breaking: wildfire forces thousands to evacuate their homes"* se clasificó como **Desastre real**, mientras que *"My phone battery died, this is a total disaster lol"* se clasificó como **No desastre**. Esto demuestra por qué es necesario modelar contexto y no limitarse a buscar palabras clave.

7. Análisis de sentimiento

Se aplicó VADER al texto original. El puntaje compuesto se clasificó como positivo cuando fue ≥ 0.05 , negativo cuando fue ≤ -0.05 y neutral en el intervalo restante.

Sentimiento	Tweets	Porcentaje
Negativo	3707	48.7%
Neutral	2013	26.4%
Positivo	1893	24.9%

Tabla 4. Distribución general del sentimiento: casi la mitad de los tweets se clasificó como negativa.




Figura 8. Distribución porcentual de VADER dentro de cada categoría real.

8. Tweets más negativos y positivos

ID	Categoría	Compound	Tweet
10689	No desastre	-0.9883	wreck? wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck wreck?
9172	Desastre real	-0.9686	@Abu_Baraa1 Suicide bomber targets Saudi mosque at least 13 dead - Suicide bomber targets Saudi mosque at least 13 dead This is ridiculous
9166	Desastre real	-0.9623	Suicide bomber kills 15 in Saudi security site mosque - A suicide bomber killed at least 15 people in an attack on... http://t.co/FY0r9o7Xsl
9137	Desastre real	-0.9595	? 19th Day Since 17-Jul-2015 -- Nigeria: Suicide Bomb Attacks Killed 64 People; Blamed: Boko Haram [L.A. Times/AP] http://t.co/O2cdKpSDfp
9159	Desastre real	-0.9552	17 killed in SQUªArabia mosque suicide bombing A suicide bomber attacked a mosque in Aseer south-western Saudi... http://t.co/pMTQhiVsXX

ID	Categoría	Compound	Tweet
4213	No desastre	-0.9549	at the lake <i>sees a dead fish</i> me: poor little guy i wonder what happened ashley: idk maybe it drowned wtf ????????
682	Desastre real	-0.9538	illegal alien released by Obama/DHS 4 times Charged With Rape & Murder of Santa Maria CA Woman Had Prior Offenses http://t.co/MqP4hF9GpO
2225	Desastre real	-0.9524	Bomb Crash Loot Riot Emergency Pipe Bomb Nuclear Chemical Spill Gas Ricin Leak Violence Drugs Cartel Cocaine Marijuana Heroine Kidnap Bust
9765	Desastre real	-0.9500	Bomb head? Explosive decisions dat produced more dead children than dead bodies trapped tween buildings on that day in September there
9940	Desastre real	-0.9493	@cspan #Prez. Mr. President you are the biggest terrorist and trouble maker in the world. You create terrorist you sponsor terrorist.

Tabla 5. Diez tweets con menor puntaje compuesto. Ocho pertenecen a desastre real y dos a no desastre.

ID	Categoría	Compound	Tweet
10028	No desastre	0.9730	Check out 'Want Twister Tickets AND A VIP EXPERIENCE To See SHANIA? CLICK HERE:' at http://t.co/3GEROQ49o1 I would Love Love Love!! To win
9345	No desastre	0.9564	@thoutaylorbrown I feel like accidents are just drawn to you but I'm happy you've survived all of them. Hope you're okay!!!
8989	Desastre real	0.9471	Today's storm will pass; let tomorrow's light greet you with a kiss. Bask in this loving warmth; let your soul return to bliss.
4541	No desastre	0.9423	@batfanuk we enjoyed the show today. Great fun. The emergency non evacuation was interesting. Have a great run.
4844	No desastre	0.9423	@batfanuk we enjoyed the show today. Great fun. The emergency non evacuation was interesting. Have a great run.
9710	No desastre	0.9394	Maaaaan I love Love Without Tragedy by @rihanna I wish she made the whole song
8994	No desastre	0.9376	Free Ebay Sniping RT? http://t.co/B231UI1O1K Lumbar Extender Back Stretcher Excellent Condition!! ?Please Favorite & Share
3525	Desastre real	0.9356	@Raishimi33 :) well I think that sounds like a fine plan where little derailment is possible so I applaud you :)
1453	No desastre	0.9345	I'm not a Drake fan but I enjoy seeing him body-bagging people. Great marketing lol.
9386	No desastre	0.9344	@duchovbutt @Starbuck_Scully @MadMakNY @davidduchovny yeah we survived 9 seasons and 2 movies. Let's hope for the good. There's hope ??????

Tabla 6. Diez tweets con mayor puntaje compuesto. Ocho pertenecen a no desastre y dos a desastre real. Un texto aparece duplicado porque así está presente en el dataset original.

9. ¿Los tweets de desastre real son más negativos?

Categoría	Tweets	Negatividad media	Mediana	Compound medio	% negativos
No desastre	4342	0.132	0.088	-0.061	42.5%
Desastre real	3271	0.174	0.157	-0.265	56.9%

Tabla 7. Resumen de negatividad por categoría. La diferencia de negatividad media fue +0.0413.

La prueba U de Mann-Whitney unilateral produjo $U=8,141,444$, $p=2e-30$ y correlación biserial por rangos=0.146. Existe evidencia de mayor negatividad en los tweets de desastre real, aunque el tamaño del efecto es pequeño.




Figura 9. Distribuciones de negatividad y valencia global. La amplia superposición muestra que el sentimiento no sustituye al contenido textual.

10. Inclusión de la negatividad en el modelo

Se creó la variable `negatividad` con la proporción negativa de VADER. Para una comparación controlada se conservaron la misma partición, el mismo TF-IDF, el mismo clasificador y los mismos hiperparámetros. La única diferencia fue agregar la columna numérica mediante `ColumnTransformer`.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
TF-IDF	0.823	0.836	0.732	0.781	0.869
TF-IDF + negatividad	0.822	0.833	0.732	0.779	0.869

Tabla 8. Comparación en la misma prueba final. El cambio absoluto en F1 fue -0.0013, equivalente a -0.16%.




Figura 10. La negatividad no mejoró ninguna métrica de manera relevante. El recall permaneció igual y F1 disminuyó levemente. TF-IDF ya contiene términos y expresiones relacionados con violencia, muerte, incendios y ataques, por lo que el puntaje agregado aporta información parcialmente redundante.

11. Limitaciones y conclusiones

Naive Bayes complementario con TF-IDF de unigramas y bigramas fue el mejor enfoque evaluado. Los bigramas ayudan a interpretar casos ambiguos, pero su ganancia global fue pequeña; filtrar términos únicos tuvo mayor impacto. VADER confirmó que los desastres reales tienden a tener tono más negativo, pero la negatividad no agregó señal predictiva útil al modelo textual.

La principal limitación metodológica son los textos repetidos: 37 filas de prueba tienen un texto crudo idéntico en entrenamiento y 222 coinciden después de limpiar. Esto puede volver ligeramente optimista el rendimiento. En una extensión futura convendría agrupar o deduplicar textos antes de dividir, resolver etiquetas contradictorias y comparar el resultado. VADER también puede fallar ante sarcasmo, lenguaje figurado, noticias citadas y artefactos de codificación.

Reproducibilidad

El análisis se distribuye en cuatro notebooks: `analisis_exploratorio.ipynb`, `limpieza.ipynb`, `analisis_post_limpieza.ipynb` y `modelado_y_sentimiento.ipynb`; las funciones reutilizables están en `src/`. Se fijó `random_state=42`, se usaron particiones estratificadas y todas las transformaciones aprendidas permanecieron dentro de pipelines. Las dependencias están declaradas en `requirements.txt` y los recursos de VADER se alojan bajo `data/nltk_data`.

Material preparado para la entrega

Elemento	Ubicación	Estado
Informe editable	docs/Laboratorio_5_informe.md	Completo
Informe final	docs/Laboratorio_5_informe.pdf	Completo
Análisis exploratorio	notebook/analisis_exploratorio.ipynb	Ejecutado
Limpieza y n-gramas	notebook/limpieza.ipynb y analisis_post_limpieza.ipynb	Ejecutado
Modelos, función y sentimiento	notebook/modelado_y_sentimiento.ipynb	Ejecutado sin errores
Código reutilizable	src/	Disponible
Repositorio	github.com/Vann06/Data-Science	Disponible

Tabla 9. Componentes técnicos que respaldan la reproducibilidad y la entrega final.

Referencias

- Kaggle. *Natural Language Processing with Disaster Tweets*. <https://www.kaggle.com/competitions/nlp-getting-started/data>
- Hutto, C. J., y Gilbert, E. (2014). *VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text*. Proceedings of ICWSM.
- Jurafsky, D., y Martin, J. H. *Speech and Language Processing*. <https://web.stanford.edu/~jurafsky/slp3/>
- NLTK Project. *Natural Language Toolkit documentation*. <https://www.nltk.org/>
- scikit-learn developers. *Working with text data* y documentación de `TfidfVectorizer`, `Pipeline` y `ComplementNB`. https://scikit-learn.org/stable/tutorial/text_analytics/working_with_text_data.html
- Mueller, A. *wordcloud documentation*. https://amueller.github.io/word_cloud/
- Virtanen, P. et al. (2020). *SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python*. Nature Methods, 17, 261-272.